

# Statistik für Data Scientists

Vorlesung 2A: Glossar

**Prof. Dr. Siegfried Handschuh**

Universität St. Gallen

# 1. Lagekennzahlen

- **Mittelwert ( $\bar{x}$ ):** Das arithmetische Mittel, die Summe aller Werte geteilt durch ihre Anzahl. Er ist sehr empfindlich gegenüber **Ausreissern** (extremen Werten) und kann dadurch verzerrt werden.
- **Median ( $Q_{0.5}$ ):** Der Wert, der eine geordnete Datenreihe in zwei gleich grosse Hälften teilt. Er ist das 50%-Quantil und im Gegensatz zum Mittelwert **robust** gegenüber Ausreissern.
- **Getrimmter Mittelwert:** Ein Mittelwert, bei dem ein bestimmter Prozentsatz der kleinsten und grössten Werte vor der Berechnung entfernt wird, um die Robustheit zu erhöhen.
- **Modus:** Der am häufigsten vorkommende Wert in einer Datenreihe. Er ist besonders nützlich für kategorische Daten und kann auf **Multimodalität** (mehrere "Gipfel" in der Verteilung) hinweisen.
- **Quantile und Perzentile:** Werte, die eine Datenverteilung in gleiche Teile zerlegen. **Quantile** teilen die Daten in vier Teile ( $Q_1, Q_2, Q_3$ ), während Perzentile sie in 100 Teile teilen. Quantile sind robust und bilden die Grundlage für den **Interquartilsabstand (IQR)**.

## 2. Streuungskennzahlen

- **Varianz ( $s^2$ ) und Standardabweichung (SD,  $s$ ):** Masse für die mittlere quadratische Abweichung vom Mittelwert. Die Varianz ist in quadratischen Einheiten, die **Standardabweichung** in der ursprünglichen Einheit der Daten und daher leichter interpretierbar. Beide sind **ausreisserempfindlich**.
- **Interquartilsabstand (IQR):** Die Differenz zwischen dem dritten und dem ersten Quartil ( $Q_3 - Q_1$ ). Der **IQR** misst die Spannweite der mittleren 50% der Daten und ist **robust** gegenüber Ausreissern.
- **Mittlere absolute Abweichung (MAD):** Der Median der absoluten Abweichungen vom Median. Die **MAD** ist eine sehr **robuste** Alternative zur Standardabweichung und nützlich bei schiefen Verteilungen.

### 3. Ausreisser

- **Ausreisser:** Werte, die signifikant vom Rest der Daten abweichen. Sie können Messfehler, Eingabefehler oder seltene, aber valide Beobachtungen sein.
- **Tukey Fences:** Eine einfache und **robuste** Methode zur Identifizierung von Ausreisserkandidaten basierend auf dem **IQR**. Werte, die unter  $Q_1 - 1.5 \cdot IQR$  oder über  $Q_3 + 1.5 \cdot IQR$  liegen, gelten als Ausreisser.
- **Modifizierter Z-Score:** Eine **robuste** Alternative zum klassischen Z-Score, die den Median und die **MAD** anstelle des Mittelwerts und der Standardabweichung verwendet. Er eignet sich besser für schiefe Verteilungen.

## 4. Histogramm und KDE

- **Histogramm:** Ein Diagramm, das die Häufigkeitsverteilung von Daten durch rechteckige Säulen darstellt. Jede Säule repräsentiert die Häufigkeit (oder Dichte) von Werten in einem bestimmten Intervall (**Bin**).
- **Bin-Wahl:** Die Entscheidung für die Breite der Intervalle (Bins) in einem Histogramm. Eine falsche Wahl kann die Interpretation verzerren. Regeln wie die **Freedman-Diaconis-Regel (FD)** helfen, eine optimale Bin-Breite zu finden.
- **Kernel Density Estimation (KDE):** Eine Methode zur Schätzung der Wahrscheinlichkeitsdichtefunktion einer Zufallsvariable. Im Gegensatz zum Histogramm erzeugt die **KDE** eine glatte, kontinuierliche Kurve, die die Form der Verteilung ohne diskrete Bins zeigt.
- **Bandbreite ( $h$ ):** Ein Schlüsselparameter bei der **KDE**, der die Glättung der Kurve steuert. Eine kleine Bandbreite führt zu einer zackigen, unruhigen Kurve, während eine grosse Bandbreite die Kurve zu stark glättet.

## 5. Box- und Violinplots

- **Boxplot:** Eine grafische Darstellung, die die Verteilung einer Variable durch fünf Kennzahlen zusammenfasst: Minimum, erstes Quartil ( $Q_1$ ), Median, drittes Quartil ( $Q_3$ ) und Maximum (oft dargestellt durch **Whisker**, die Ausreisser ausschliessen). Er bietet einen schnellen Überblick über Lage, Streuung und Ausreisser.
- **Violinplot:** Eine Kombination aus **Boxplot** und **KDE**. Die Form des Plots repräsentiert die Dichtefunktion (ähnlich der **KDE**), während die inneren Markierungen (z.B. ein kleiner Kasten oder Linien) die **Quartile** und den Median zeigen. Er ist nützlich, um die Form der Verteilung zu visualisieren, insbesondere bei Gruppenvergleichen.
- **Strip- und Swarmplots:** Plots, die die individuellen Rohdatenpunkte visualisieren. Sie können Boxplots oder Violinplots ergänzen, um die tatsächliche Verteilung der Punkte zu zeigen, die durch die statistischen Zusammenfassungen verborgen bleiben könnten.

## 6. ECDF und QQ-Plot

- **Empirical Cumulative Distribution Function (ECDF):** Eine binfreie und vollständige Darstellung der kumulativen Verteilung von Daten. Die **ECDF** zeigt für jeden Wert, welcher Anteil der Daten kleiner oder gleich diesem Wert ist. Sie ist sehr informativ, auch bei kleinen Datensätzen, und erlaubt das direkte Ablesen von **Quantilen**.
- **Quantile-Quantile Plot (QQ-Plot):** Ein Diagramm, das die **Quantile** einer Stichprobe gegen die **Quantile** einer theoretischen Verteilung (z. B. der Normalverteilung) aufträgt. Liegen die Punkte auf einer geraden Linie, stimmen die Verteilungen gut überein. Abweichungen von der Linie zeigen Abweichungen wie **Schiefte** oder **schwere Tails** (d. h. eine grosse Anzahl von extremen Werten).
- **Schwere Tails (Heavy Tails):** Eine Eigenschaft einer Verteilung, bei der die Wahrscheinlichkeit für extreme Werte höher ist als bei einer Normalverteilung. Im **QQ-Plot** zeigt sich dies durch eine Krümmung am oberen und unteren Ende.