

# **Statistik für Data Scientists**

## **Vorlesung 6: Schätzen & Konfidenzintervalle**

Prof. Dr. Siegfried Handschuh  
DS-NLP  
Universität St. Gallen

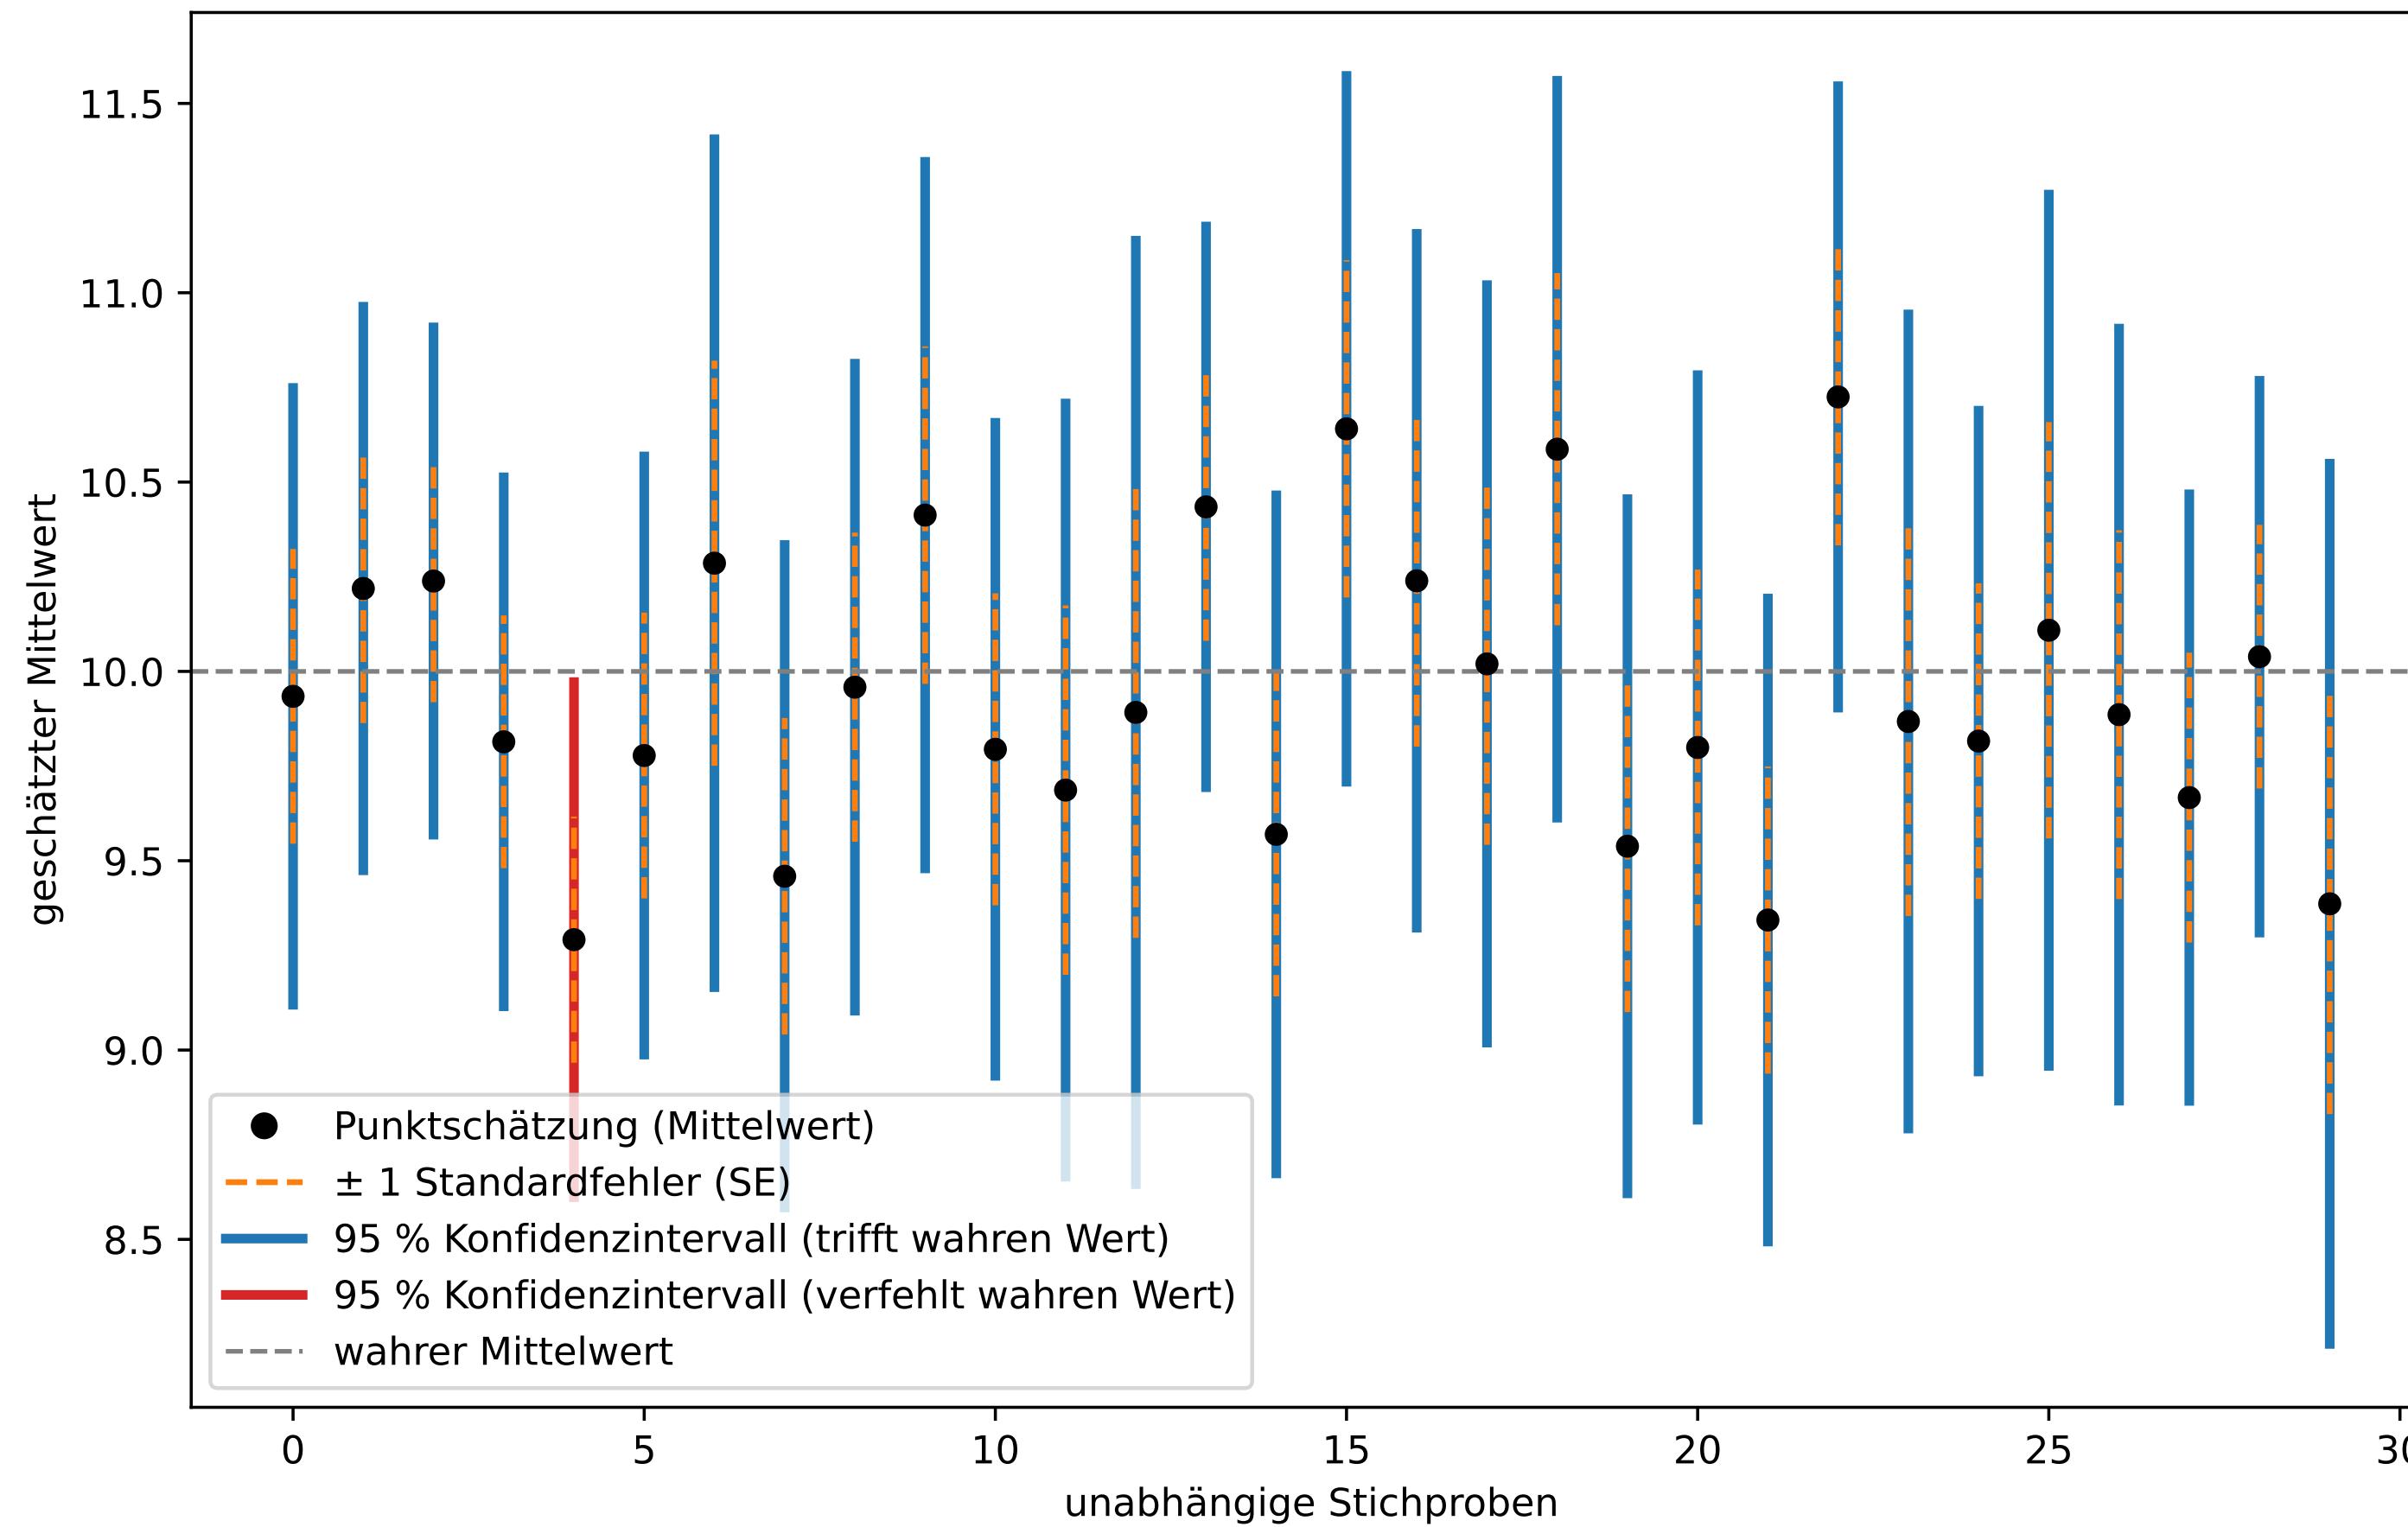
# Recap & Ziele heute

- Recap: Wahrscheinlichkeit & Verteilungen.
- Heute: Punktschätzung, Standardfehler, Konfidenzintervalle.
- Anteile: Wald vs. Wilson.
- Bootstrap als praxisnahe Alternative.
- Planung: Stichprobengrösse via Margin of Error.

# Punktschätzung, Standardfehler, Konfidenzintervalle.

- Wir können selten **alle** Menschen oder Dinge messen.
- Darum nehmen wir **eine Stichprobe** – eine kleine Gruppe – und **schätzen** daraus das Ganze.
- Beispiele:
  - Wie hoch ist der **durchschnittliche Puls** in eurer Klasse?
  - Wie gross ist der **Anteil der Menschen**, die TikTok **täglich** nutzen?
- Unsere Schätzung ist also ein **bestmöglicher Tipp**, basierend auf begrenzten Daten.

# Punktschätzung, Standardfehler (SE) und 95 %-Konfidenzintervalle (t)



# Beispiel: TikTok in der Vorlesung ( $n = 5$ )

- In der Vorlesung sitzen 32 Studierende.
- Wir wollen wissen, wie viele davon täglich TikTok schauen, aber wir fragen nur 5 zufällig ausgewählte Personen. →  $n$
- Von diesen 5 sagen 3 „Ja“ → beobachteter Anteil  $\hat{p} = 3 / 5 = 0.6$  (60%).
- Das ist unsere Punktschätzung für den wahren Anteil  $p$  in der ganzen Vorlesung.
- Mit dem Standardfehler berechnen wir, wie unsicher diese Schätzung ist:

$$SE(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} = \sqrt{\frac{0.6(0.4)}{5}} \approx 0.22$$

- Das 95%-Konfidenzintervall (nach Abraham Wald) lautet:

$$\hat{p} \pm 1.96 \times SE(\hat{p}) \approx 0.6 \pm 0.43 \Rightarrow [0.17, 1.00]$$

→ Wir schätzen, dass zwischen 17 % und 100 % täglich TikTok schauen.

# Beispiel: TikTok in der Vorlesung ( $n = 10$ )

- In der Vorlesung sitzen **32 Studierende**.
- Wir fragen **10 zufällig ausgewählte Personen**, wie viele davon **täglich TikTok schauen**.
- **6 sagen „Ja“** → beobachteter Anteil  $\hat{p} = 6 / 10 = 0.6$  (60 %).
- Das ist unsere **Punktschätzung** für den wahren Anteil **p** in der ganzen Vorlesung.
- Mit dem **Standardfehler** berechnen wir die Unsicherheit der Schätzung:

$$SE(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} = \sqrt{\frac{0.6(0.4)}{10}} \approx 0.155$$

- Das **95%-Konfidenzintervall** (nach **Abraham Wald**) lautet:

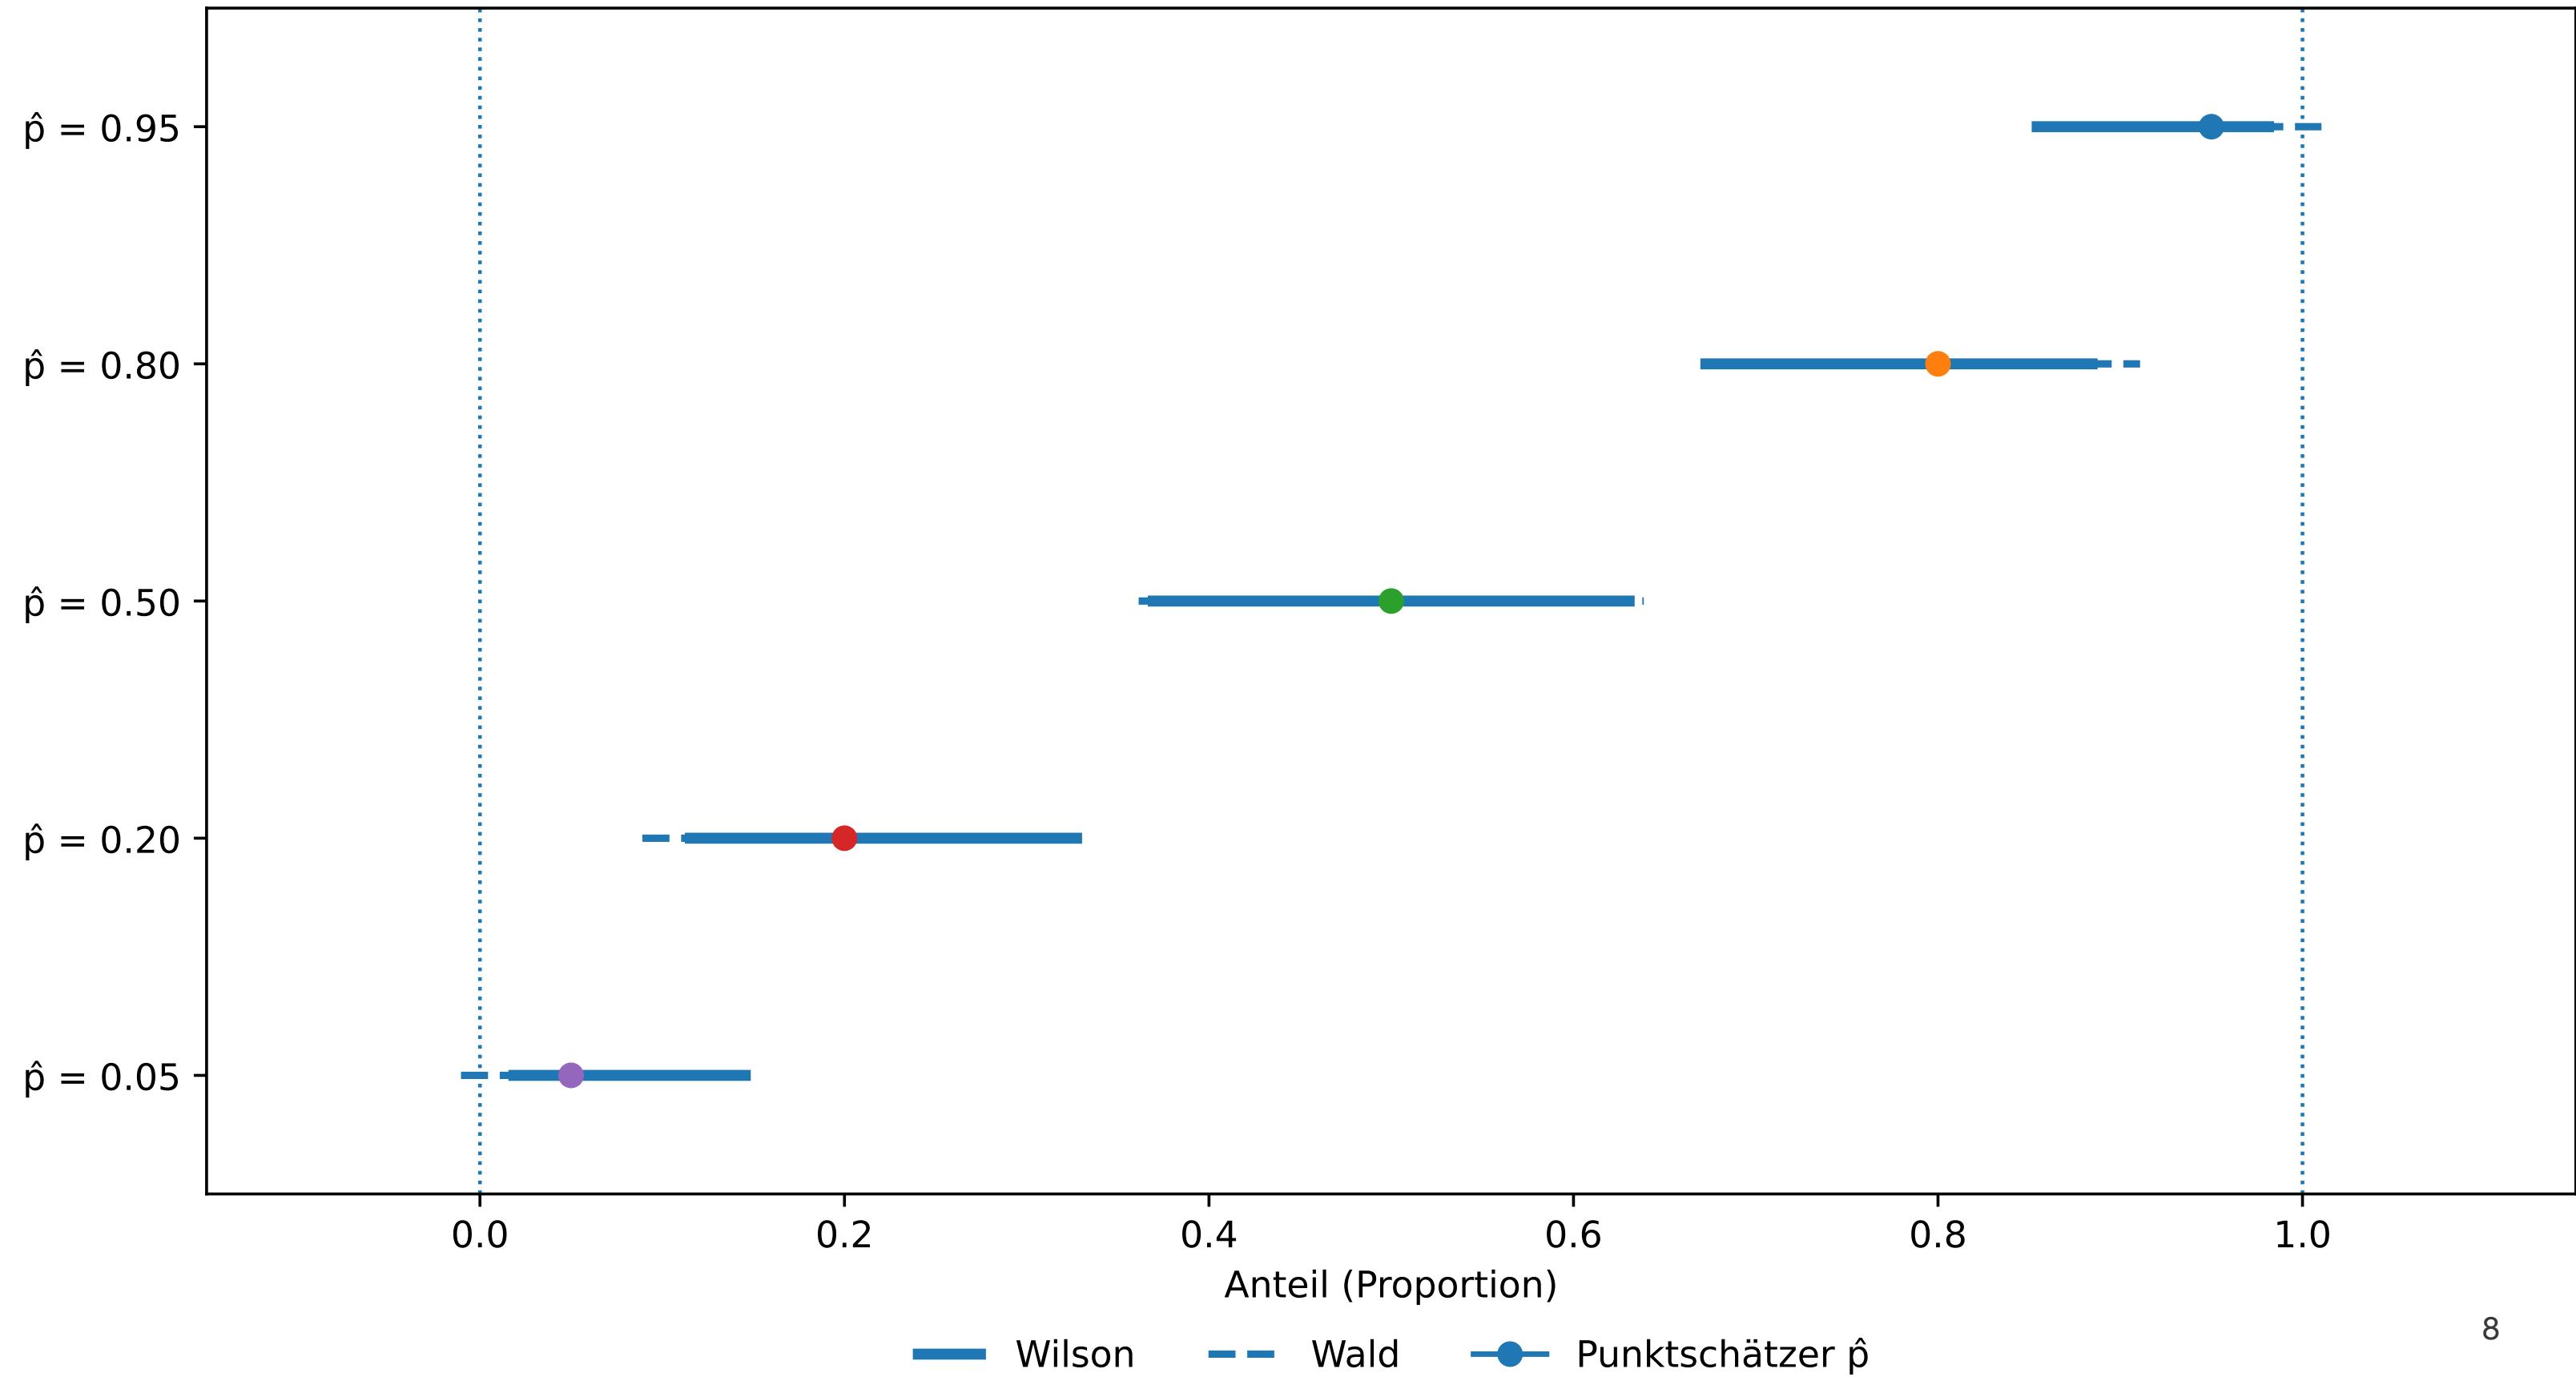
$$\hat{p} \pm 1.96 \times SE(\hat{p}) \approx 0.6 \pm 0.30 \Rightarrow [0.30, 0.90]$$

→ Wir schätzen, dass **zwischen 30 % und 90 %** der Studierenden täglich TikTok schauen.

# Anteile: Wald vs. Wilson

- Abraham Wald (1902–1950) vs Edwin Bidwell Wilson (1879–1964)
- Wir wollen wissen, wie sicher ein beobachteter Prozentwert (Anteil) ist.
- Beispiel: 30 % der Befragten wählen Partei A, aber wie genau ist das?
- Dafür gibt es zwei Wege:
  - Wald: schnell gerechnet, aber kann unrealistische Werte liefern.
  - Wilson: etwas aufwendiger, aber stabil und immer zwischen 0 % und 100 %.
- Moderne Statistik nutzt Wilson → weil er Unsicherheit ehrlicher darstellt.

Anteile: Wald vs. Wilson – 95%-Konfidenzintervalle  
( $n = 50$ ,  $z \approx 1.96$ )



# Bootstrap: praxisnahe Alternative

- Klassische Formeln brauchen oft **strenge Annahmen** (z. B. Normalverteilung).
- Der **Bootstrap** funktioniert auch dann, wenn diese Annahmen **nicht** gelten.
- Idee: Die vorhandene **Stichprobe als Mini-Welt** behandeln.
- Viele neue Stichproben **mit Zurücklegen** ziehen → jedes Mal neu schätzen.
- So entsteht eine **Verteilung der Schätzwerthe**, aus der man SE und CI direkt ablesen kann.
- **Vorteil:** funktioniert bei kleinen n, schießen Daten und komplizierten Schätzern.



# Bootstrap: Intuition

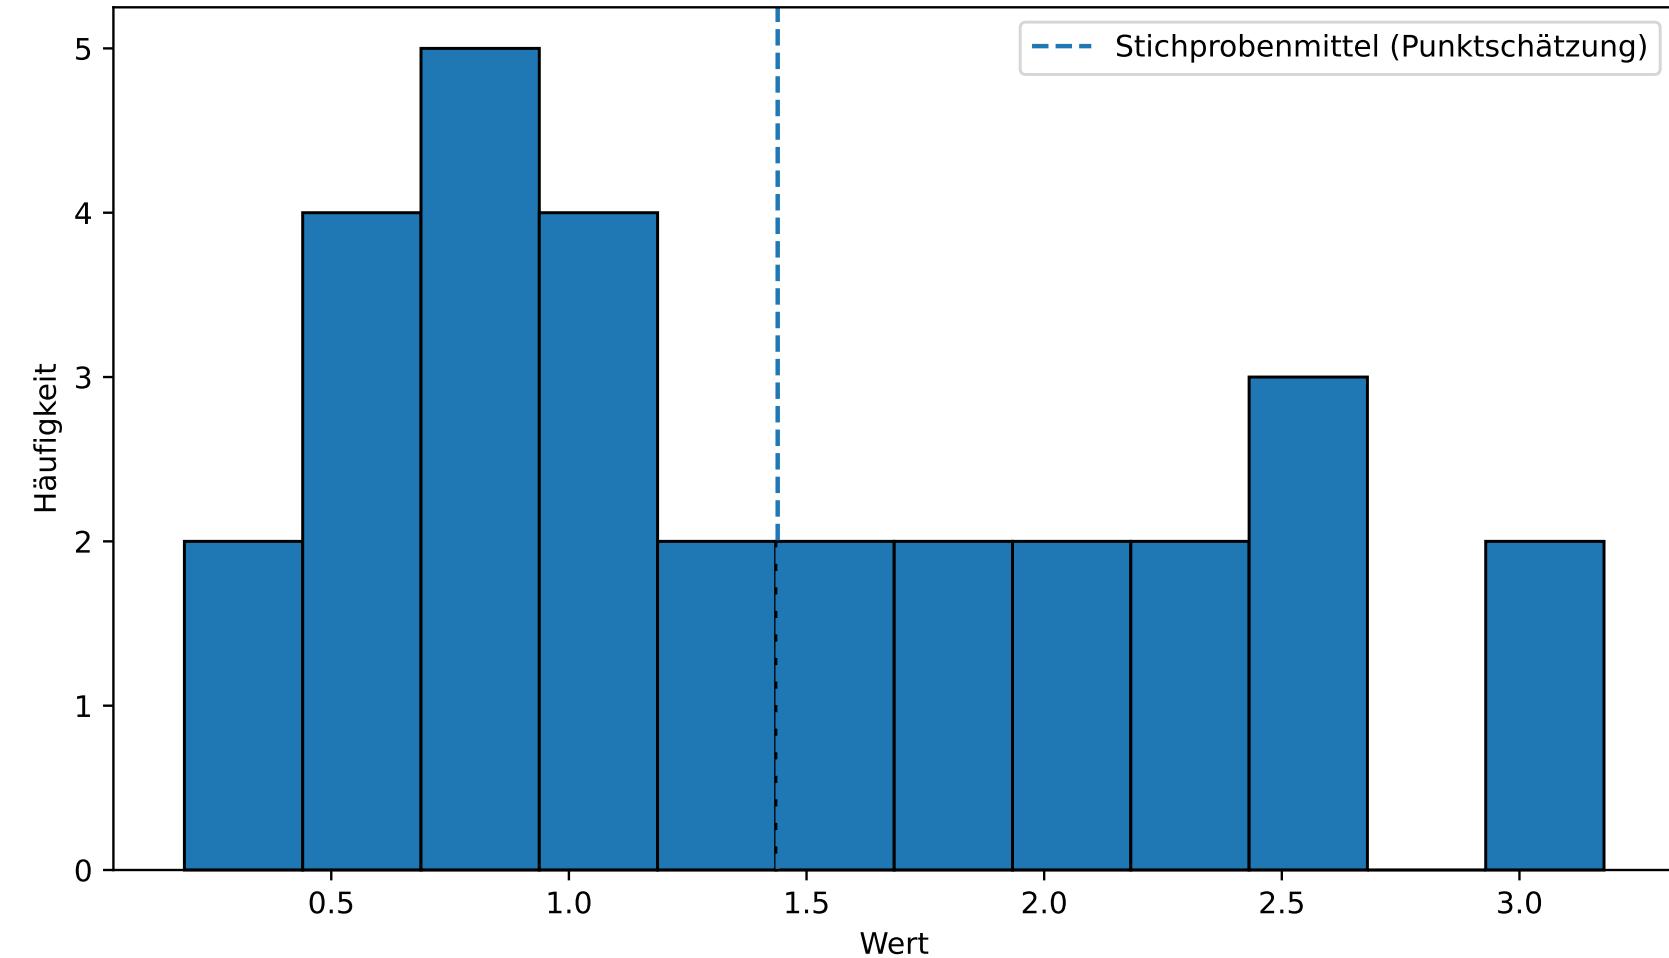
Du misst die Schlafdauer von 30 Studierenden.

Du kennst nicht die Schlafgewohnheiten aller 9879 Studierenden der HSG.

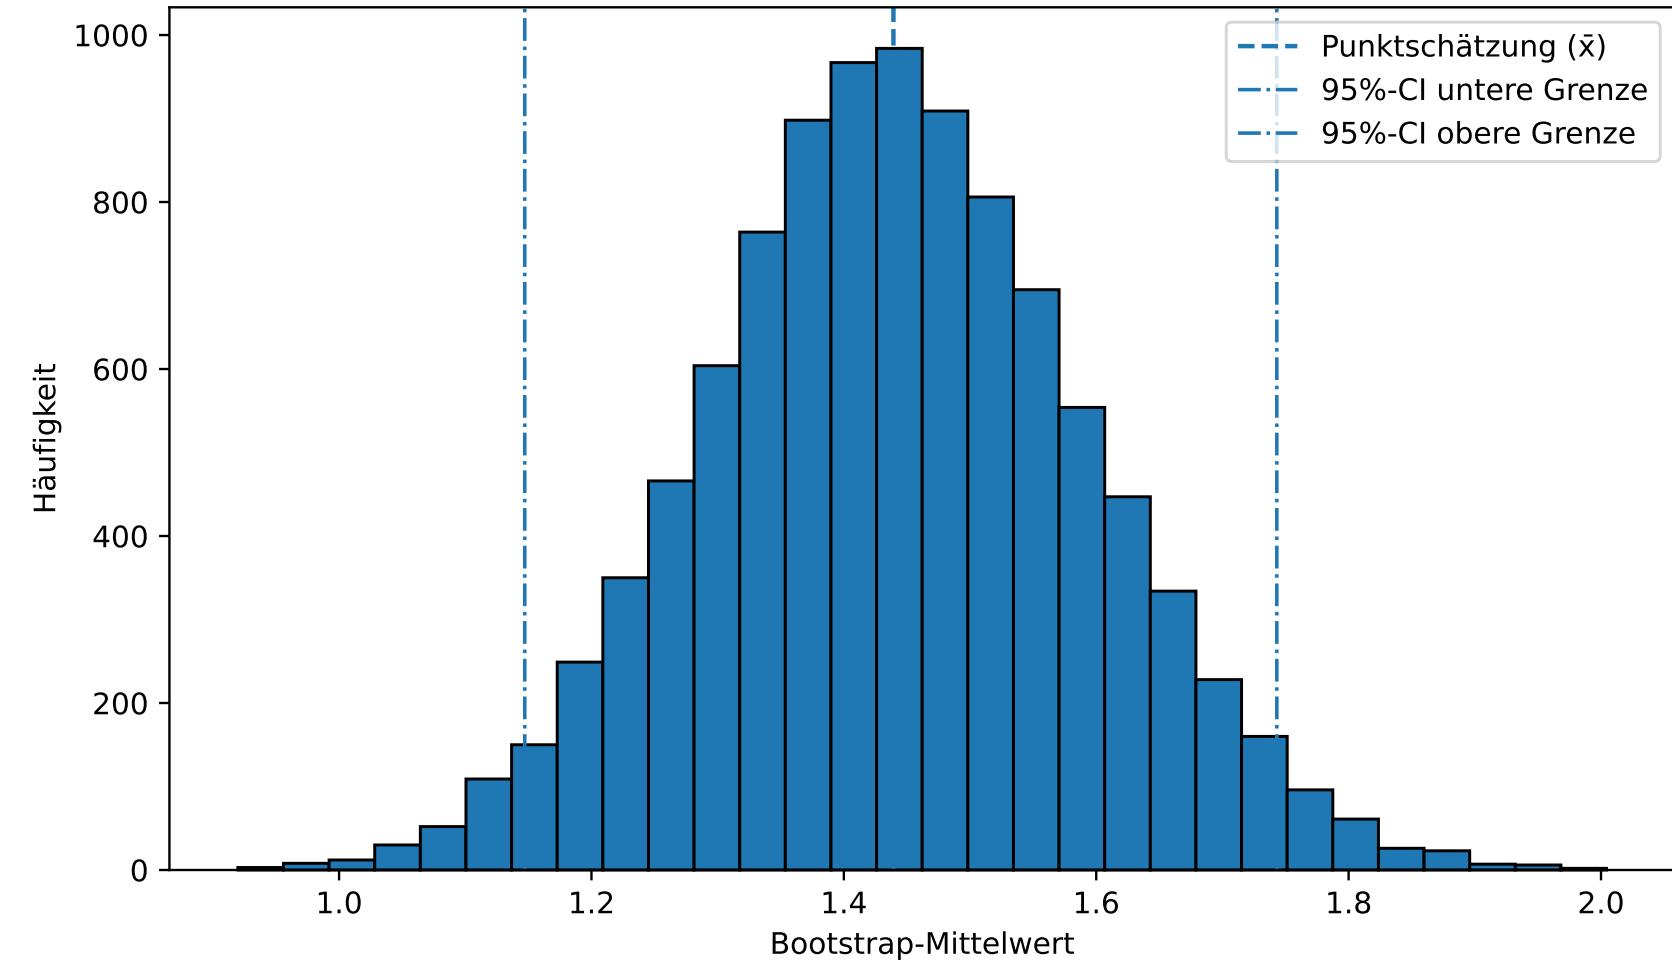
Aber du tust so, als wäre deine Stichprobe (die 30 Werte) eine kleine Version der gesamten Uni.

Dann ziehst du **tausendmal** neue Stichproben aus diesen 30 Werten → und siehst, wie stark der durchschnittliche Schlaf schwankt.

Original-Stichprobe: schiefe Daten (Mini-Welt)

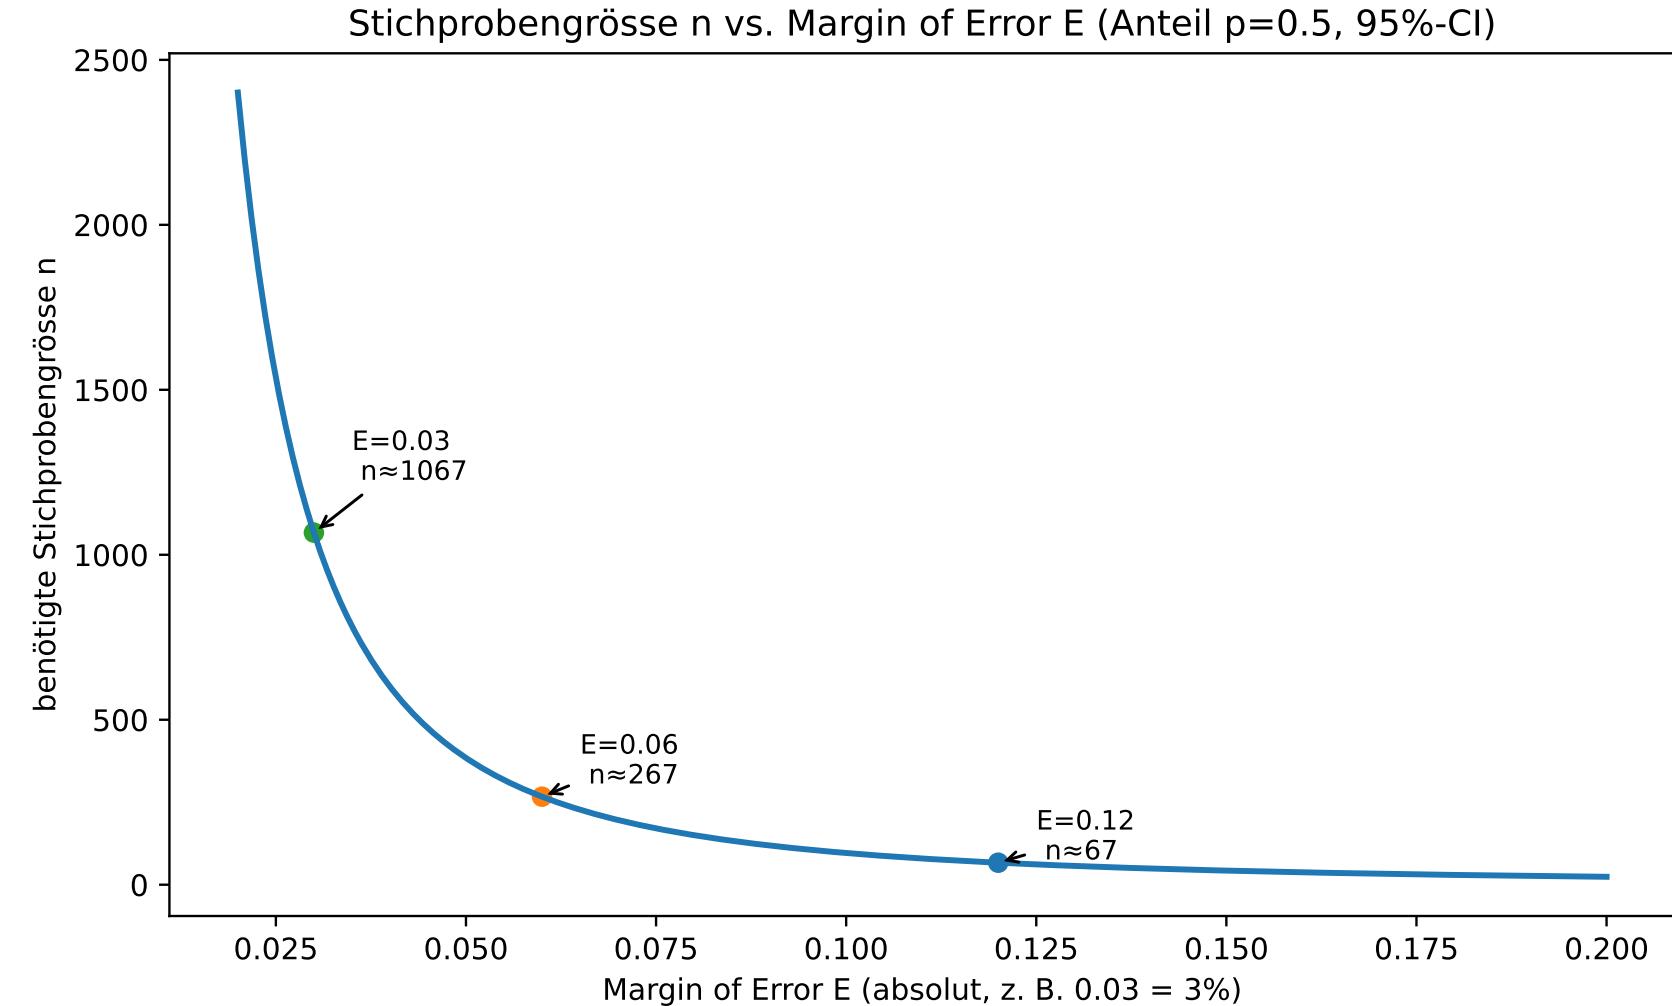
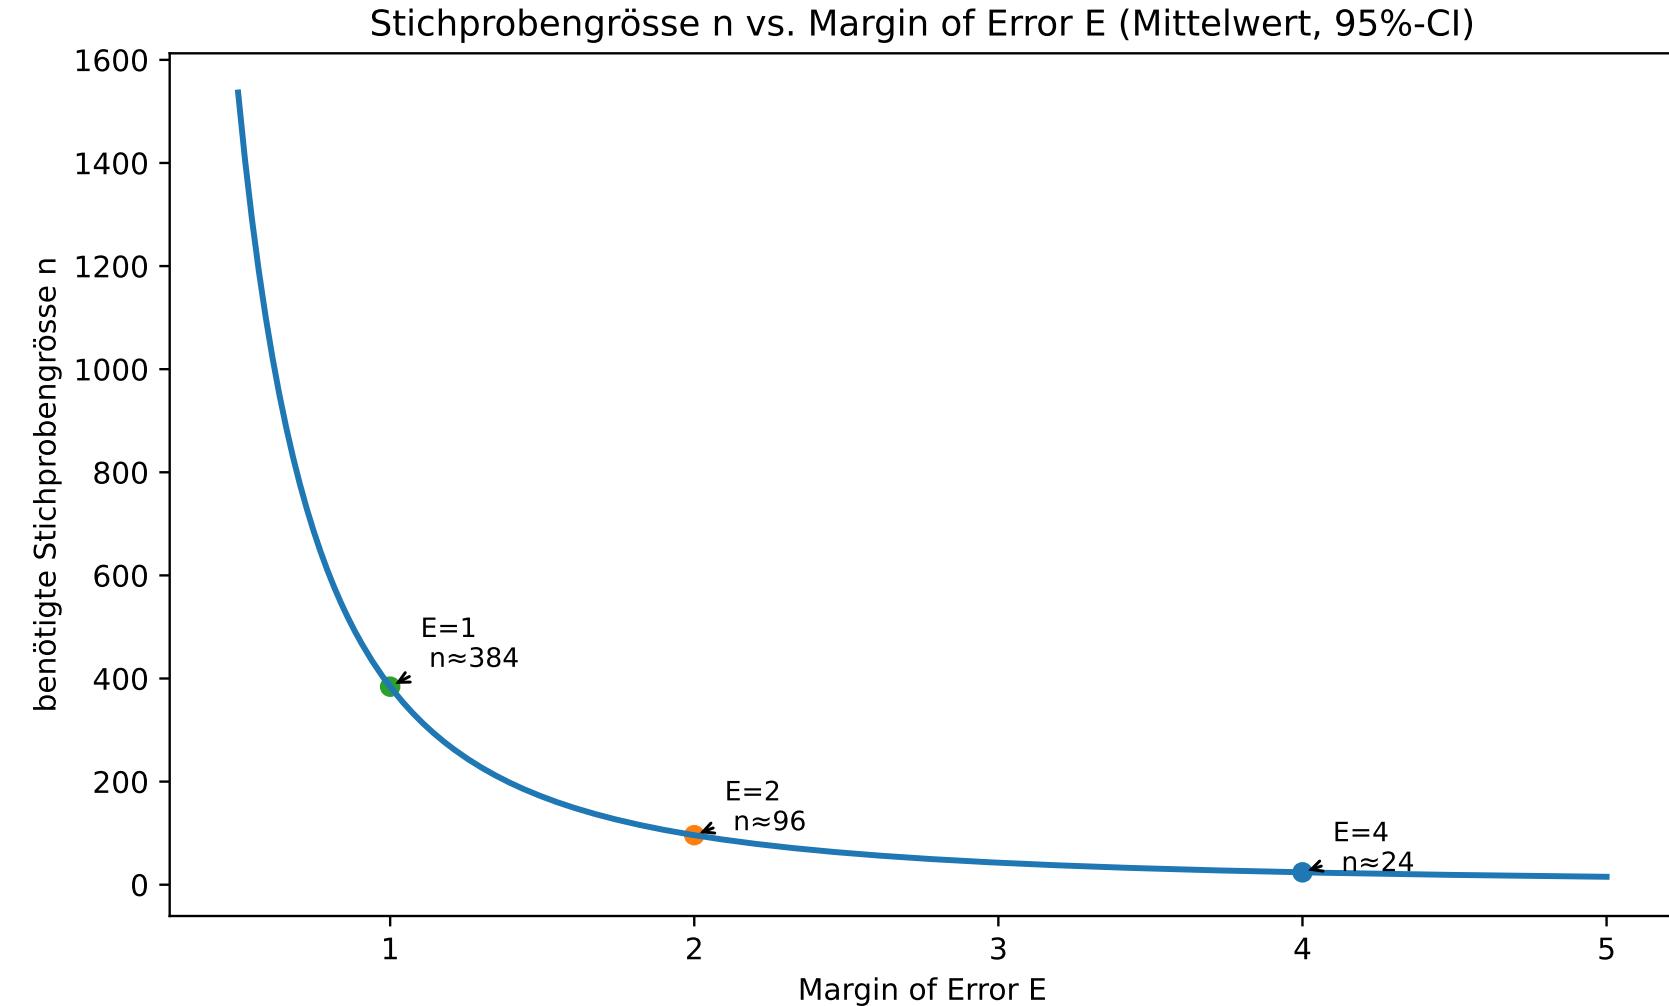


Bootstrap-Verteilung der Mittelwerte ( $B = 10'000$ )

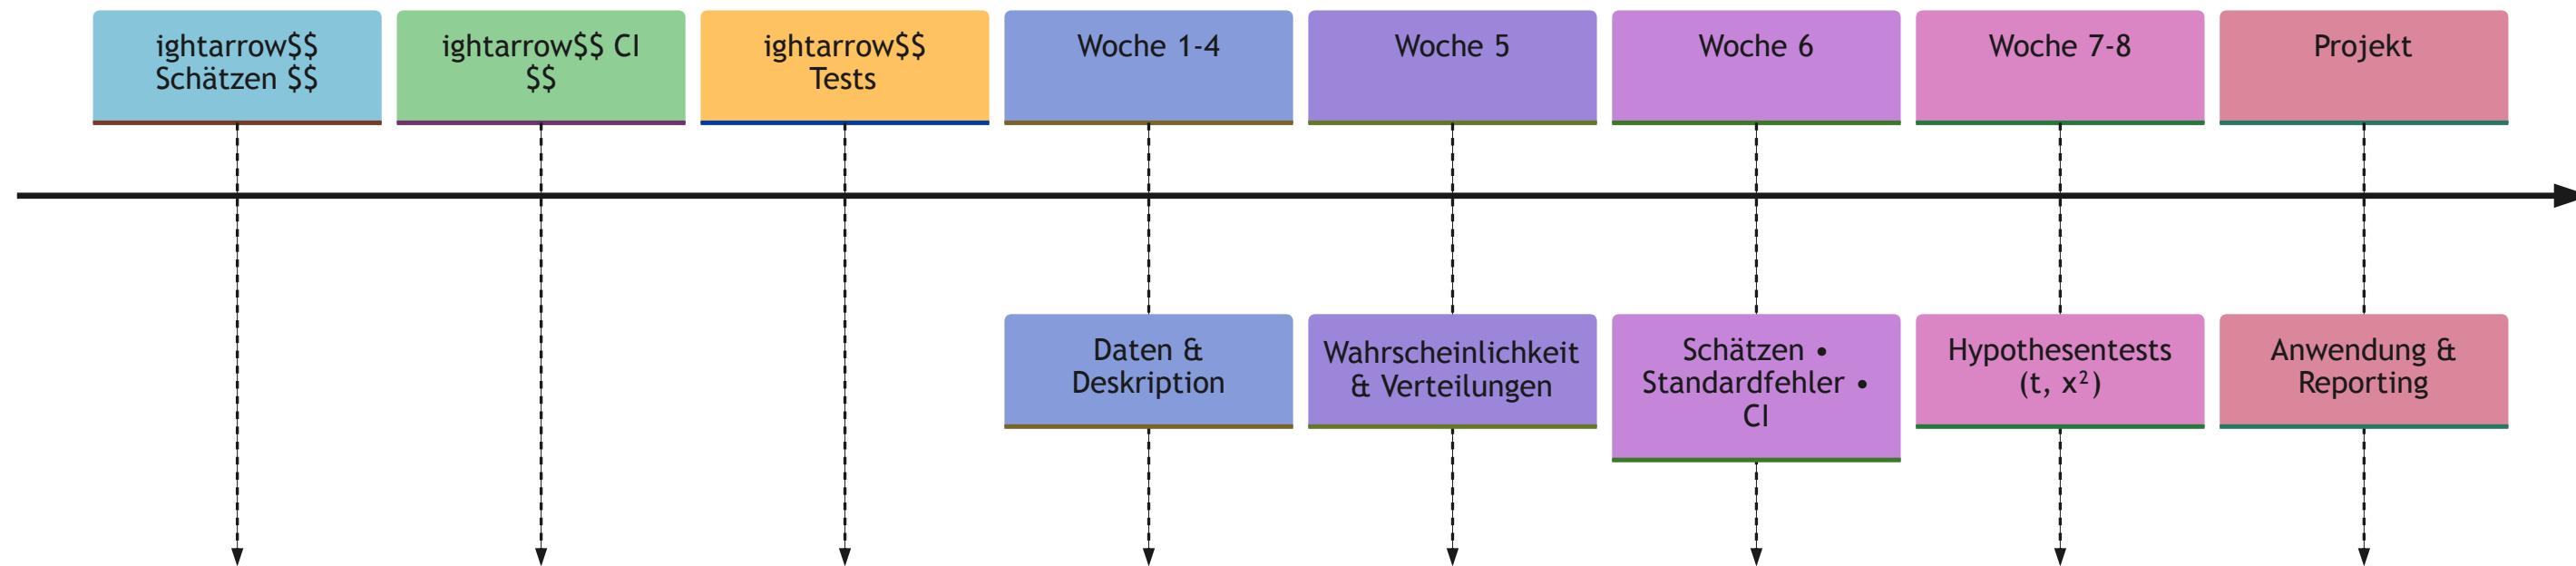


# Planung: Stichprobengrösse via Margin of Error

- Bevor wir Daten erheben oder messen, müssen wir wissen: Wie viele Beobachtungen brauchen wir?
- Der Margin of Error (Fehlergrenze) zeigt, wie genau unsere Schätzung am Ende sein soll.
- Je kleiner der erlaubte Fehler, desto mehr Daten müssen wir sammeln – und zwar quadratisch mehr.
- Beispiel: Wenn der Fehler halb so gross sein soll, braucht man viermal so viele Messungen oder Befragungen.
- Ziel: nicht «so viel wie möglich», sondern so viel wie nötig, um verlässlich zu schätzen.



# Daten \$\$



Primer

## Grundgesamtheit



Stichprobe



Vollerhebung



# Population, Stichprobe & Parameter

- Wir wollen etwas über eine **grosse Gruppe (Population)** herausfinden, z. B. den **durchschnittlichen Puls** aller Studierenden.
- Weil wir nicht alle messen können, nehmen wir eine **kleinere Gruppe (Stichprobe)**.
- Die Population hat feste, aber **unbekannte Werte** (Parameter):
  - Mittelwert  $\mu$ , Varianz  $\sigma^2$ , Anteil  $p$ .
  - Aus der Stichprobe berechnen wir eine **Schätzung** dieser Werte, z. B. den **Mittelwert  $\bar{x}$** .
  - Der wahre Wert  $\mu$  ist **fix**, die Schätzung  $\bar{X}$  **zufällig**, sie hängt von der Stichprobe ab.

# Primer: Population, Stichprobe & Parameter

Schätzer basieren auf **Stichproben** und zielen auf **Populationsparameter**.

- **Population:** Gesamtheit; Parameter:  $\mu, \sigma^2, p$  (fix, unbekannt).
- **Stichprobe:**  $n$  Beobachtungen; ideal: zufällig und unabhängig.
- **Statistik/Schätzer:**  $T(X_1, \dots, X_n)$ ; **Schätzwert:**  $t = T(x_1, \dots, x_n)$ .
- **Beispiele:**  $\bar{X} \rightarrow \mu, \hat{p} \rightarrow p$ .

**Mini-Check:** Was ist zufällig, was fix:  $\bar{X}, \mu, \bar{x}$ ?

# Symbole verstehen: $\mu$ , $\sigma^2$ , $p$ , $n$ , $T$ , $t$ , $\bar{x}$ , $\hat{p}$ ...

- $T(X_1, \dots, X_n)$  = allgemeiner **Schätzer**, also die Rechenregel (z. B. „bilde den Durchschnitt“)
- $t = T(x_1, \dots, x_n)$  = **Schätzwert**, also das konkrete Ergebnis, wenn wir Zahlen einsetzen
- In der **Population** (der ganzen Gruppe):
  - $\mu$  (sprich: mü) = wahrer Mittelwert
  - $\sigma^2$  (sigma-Quadrat) = wahre Varianz (zeigt, wie stark die Werte streuen)
  - $p$  = wahrer Anteil oder Wahrscheinlichkeit
- In der **Stichprobe** (den gemessenen Daten):
  - $n$  = Anzahl der Beobachtungen
  - $\bar{x}$  (sprich: x quer) = Mittelwert der Stichprobe (unsere Schätzung für  $\mu$ )
  - $\hat{p}$  (sprich: p-Dach) = beobachteter Anteil (unsere Schätzung für  $p$ )

# Unterschied: Grosses $\bar{X}$ vs. kleines $\bar{x}$

- Grosses  $\bar{X}$  steht für die **Zufallsvariable** des Mittelwerts.  
→ Sie beschreibt, wie der Mittelwert über viele mögliche Stichproben schwankt.
- Kleines  $\bar{x}$  steht für den **beobachteten Mittelwert** aus einer konkreten Stichprobe.  
→ Das ist der Wert, den du tatsächlich **ausgerechnet** hast.
- Wenn man das Experiment viele Male wiederholt, bekommt man viele verschiedene  $\bar{x}$ -Werte →  
**die Gesamtheit dieser Werte ist die Verteilung von  $\bar{X}$ .**
- Kurz gesagt:
  - $\bar{X}$  = theoretisch, zufällig
  - $\bar{x}$  = beobachtet, konkret

# SD vs. SE – zwei Arten von Streuung

- Beide messen **Streuung**, aber auf **unterschiedlichen Ebenen**.

Kürzel	Bedeutung	Wofür sie steht
SD (Standard Deviation)	Standardabweichung	Wie stark <b>die Daten selbst</b> streuen
SE (Standard Error)	Standardfehler	Wie stark <b>ein Schätzer</b> (z. B. der Mittelwert) zwischen <b>Stichproben</b> schwankt

SD → beschreibt die **Variabilität innerhalb einer Stichprobe**.

SE → beschreibt die **Unsicherheit des Mittelwerts über viele Stichproben hinweg**.

# Beispiel: $\bar{X}$ vs. $\bar{x}$ mit Zahlen

- In unserer Stichprobe messen wir  $\bar{x} = 73.1 \rightarrow$  das ist der **beobachtete Schätzwert**.
- Bei einer anderen Stichprobe könnte  $\bar{x}$  z. B. 71.5 oder 74.2 sein.

Wir schätzen den **durchschnittlichen Puls aller Studierenden** an der Uni.

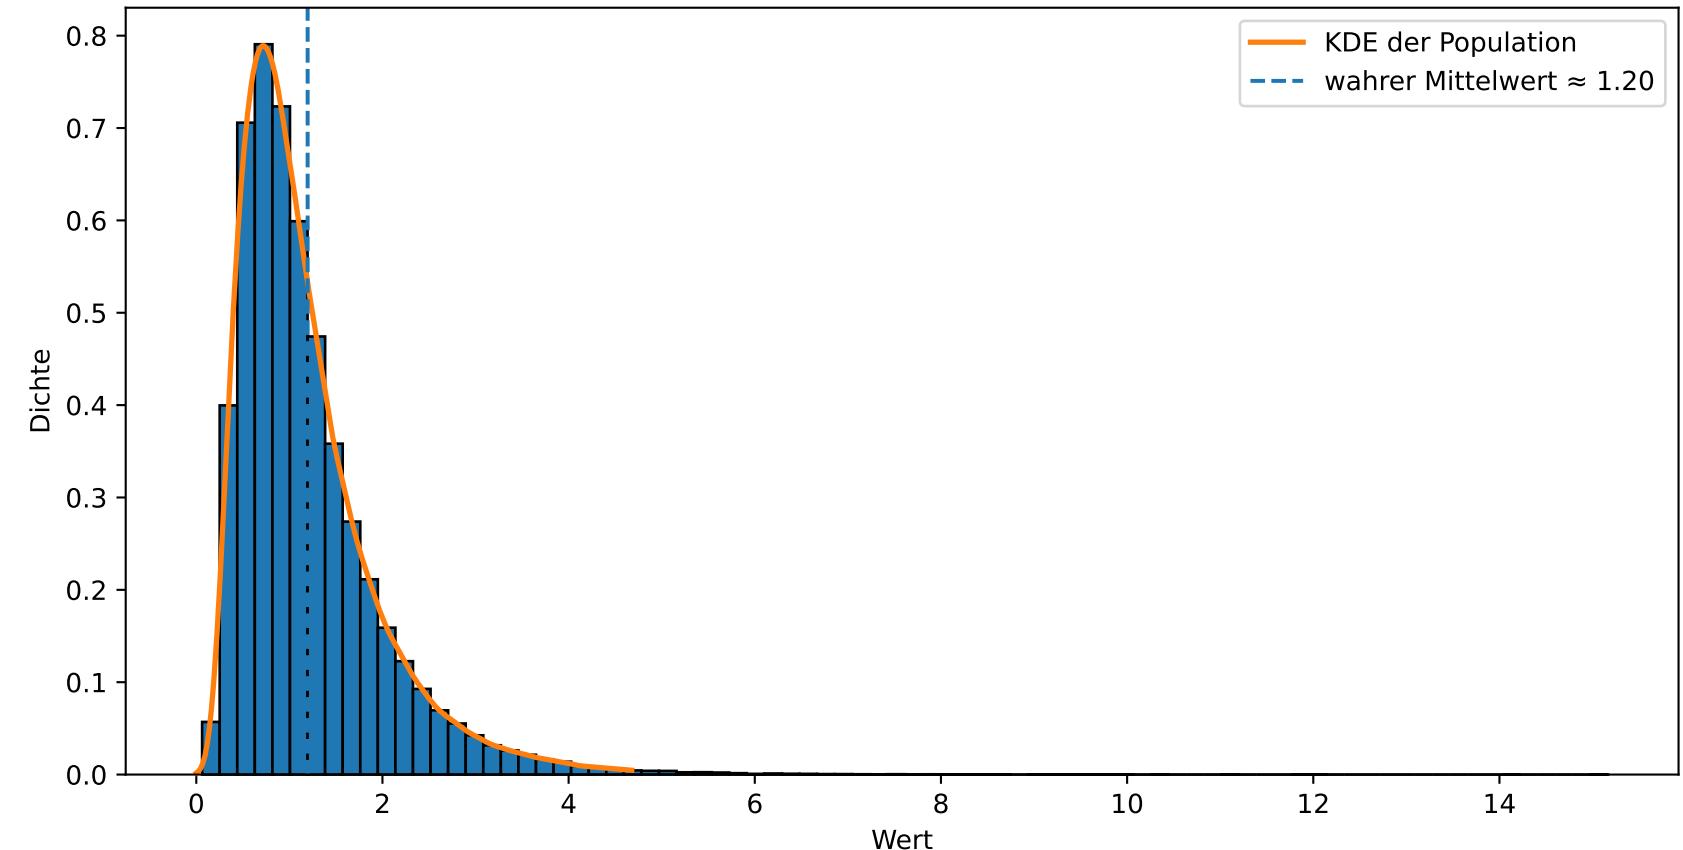
In der Population gilt:

- Wahrer Mittelwert  $\mu = 72$
- Standardabweichung  $\sigma = 8$
- Stichprobengrösse  $n = 25$

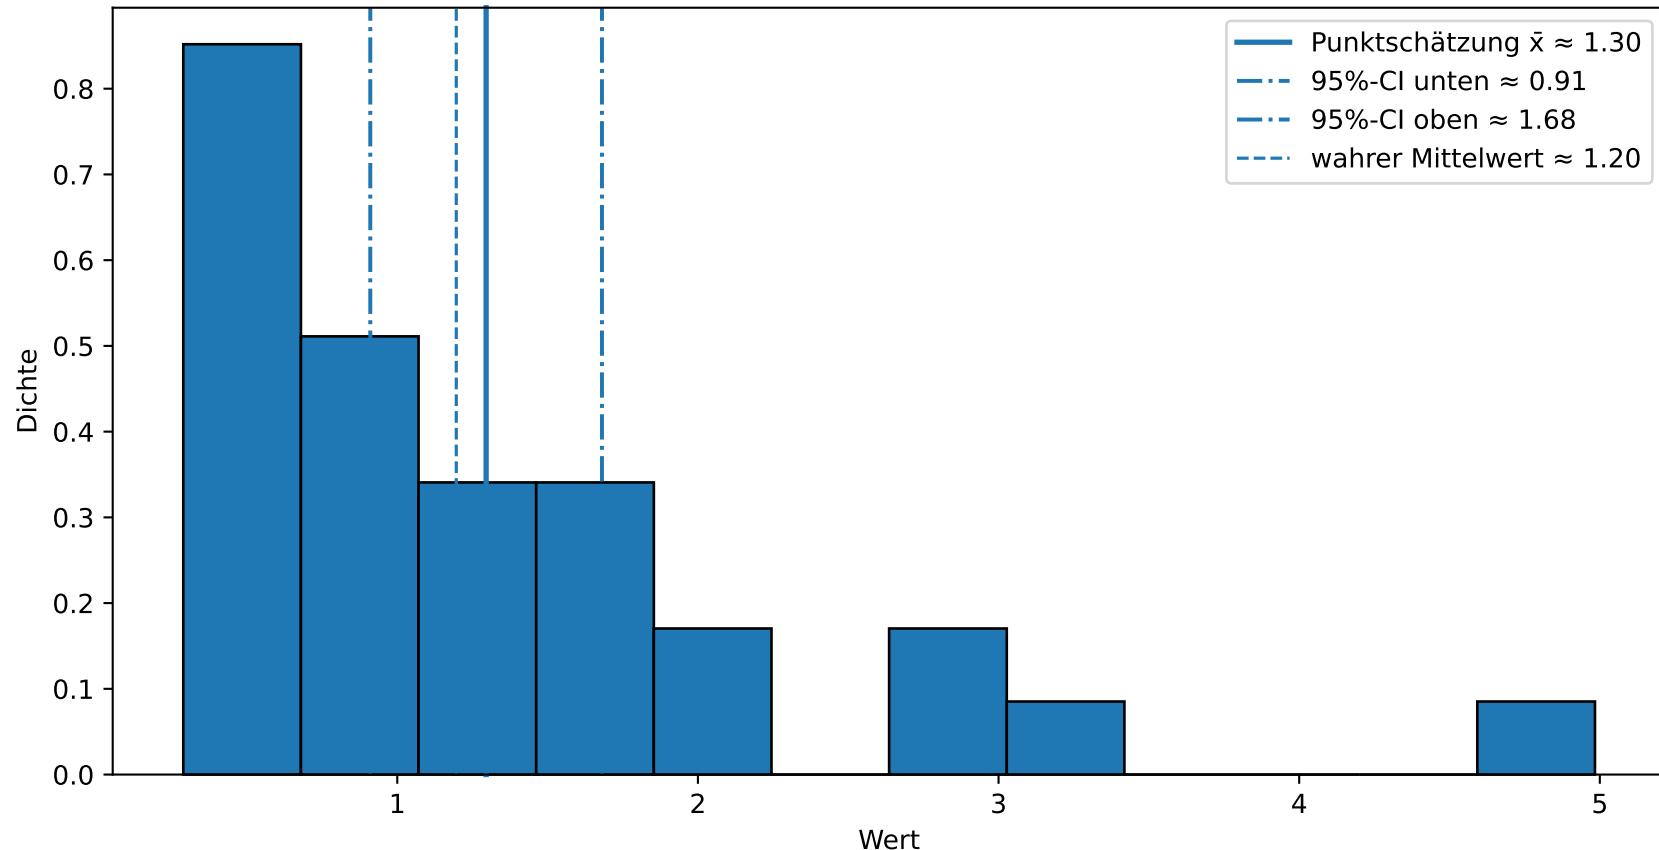
Theoretisch gilt für den Mittelwert  $\bar{X}$ :

- Erwartungswert  $E[\bar{X}] = 72$
- Standardfehler  $SE = SD(\bar{X}) = \sigma / \sqrt{n} = 1.6$
- Mögliche Werte von  $\bar{X}$  liegen meist zwischen **68.8 und 75.2**

Population: schiefe Verteilung mit "wahrem" Mittelwert



Stichprobe (n = 30): Punktschätzung und 95%-Konfidenzintervall



# Sampling & Bias

- Gute Konfidenzintervalle brauchen gute Stichproben: zufällig, unabhängig, repräsentativ.
- Eine Zufallsstichprobe verhindert systematische Verzerrungen und hält die Formeln gültig.
- Typische Bias-Fallen:
  - Selektionsbias: Nur bestimmte Personen werden befragt.
  - Nonresponse: Wer nicht antwortet, unterscheidet sich vom Rest.
  - Abhängigkeiten: Daten stammen aus Clustern oder Zeitreihen.

# Zufällig, unabhängig & repräsentativ

- Eine **zufällige Stichprobe** bedeutet: Jede Person oder jedes Objekt hat **die gleiche Chance**, ausgewählt zu werden.  
→ Beispiel: Zufallsgenerator wählt 50 Studenten aus der ganzen Uni.
- **Unabhängig** heisst: Das Ergebnis einer Messung **beeinflusst keine andere**.  
→ Beispiel: Wenn du den Puls misst, darf der Puls des ersten Studenten keinen Einfluss auf den zweiten haben.
- **Repräsentativ** bedeutet: Die Stichprobe **spiegelt die Vielfalt der Population wider**.  
→ Beispiel: Wenn du nur deine Freunde befragst, ist das **nicht repräsentativ** für die ganze Schule.
- Nur wenn alle drei Bedingungen erfüllt sind, können wir **verlässlich schätzen** und **Konfidenzintervalle** korrekt berechnen.

# Notation: Population & Stichprobe

In der Population (ganze Uni):

- $\mu$  = wahrer Durchschnitt (z. B. aller Studierenden)
- $\sigma^2$  = wahre Varianz → zeigt, wie stark die Werte streuen
- $p$  = wahrer Anteil (z. B. Anteil der Studierenden, die täglich Kaffee trinken)

Beispiel:

Wir befragen 50 Studierende über ihren täglichen Kaffeekonsum:  
→  $\mu$  = wahrer Durchschnitt (unbekannt)  
→  $\bar{x}$  = Durchschnitt aus den 50 Antworten  
→  $\hat{p}$  = Anteil der Kaffeetrinker in dieser Stichprobe

In der Stichprobe (unsere Messdaten):

- $\bar{x}$  = Mittelwert der Stichprobe → unsere Schätzung für  $\mu$
- $s^2$  = Stichprobenvarianz → Schätzung für  $\sigma^2$
- **ddof = 1** („Delta Degrees of Freedom“) korrigiert die Berechnung, damit  $s^2$  im Mittel unverzerrt ist
- $\hat{p}$  (sprich: p-Dach) = beobachteter Anteil aus der Stichprobe

# Notation: SE & Quantile verstehen

SE (Standardfehler) beschreibt, wie stark ein Schätzer schwankt, wenn man viele Stichproben zieht:

$$\text{Für den Mittelwert: } SE(\bar{x}) = \frac{\sigma}{\sqrt{n}}$$

$$\text{Für Anteile: } SE(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

Je grösser  $n$ , desto kleiner der Standardfehler → unsere Schätzungen werden stabiler.

Quantile bestimmen die Grenzen von Konfidenzintervallen:

- $z_{1-\alpha/2} \approx 1.96 \rightarrow 95\% \text{ der Werte liegen innerhalb von}$   
 $\pm 1.96 \text{ Standardabweichungen um den Mittelwert.}$
- $t_{df, 1-\alpha/2} \rightarrow \text{analog für kleinere Stichproben mit der t-Verteilung, wobei } df = n - 1.$

$1 - \frac{\alpha}{2}$  bedeutet, dass wir beide Seiten der Verteilung betrachten:

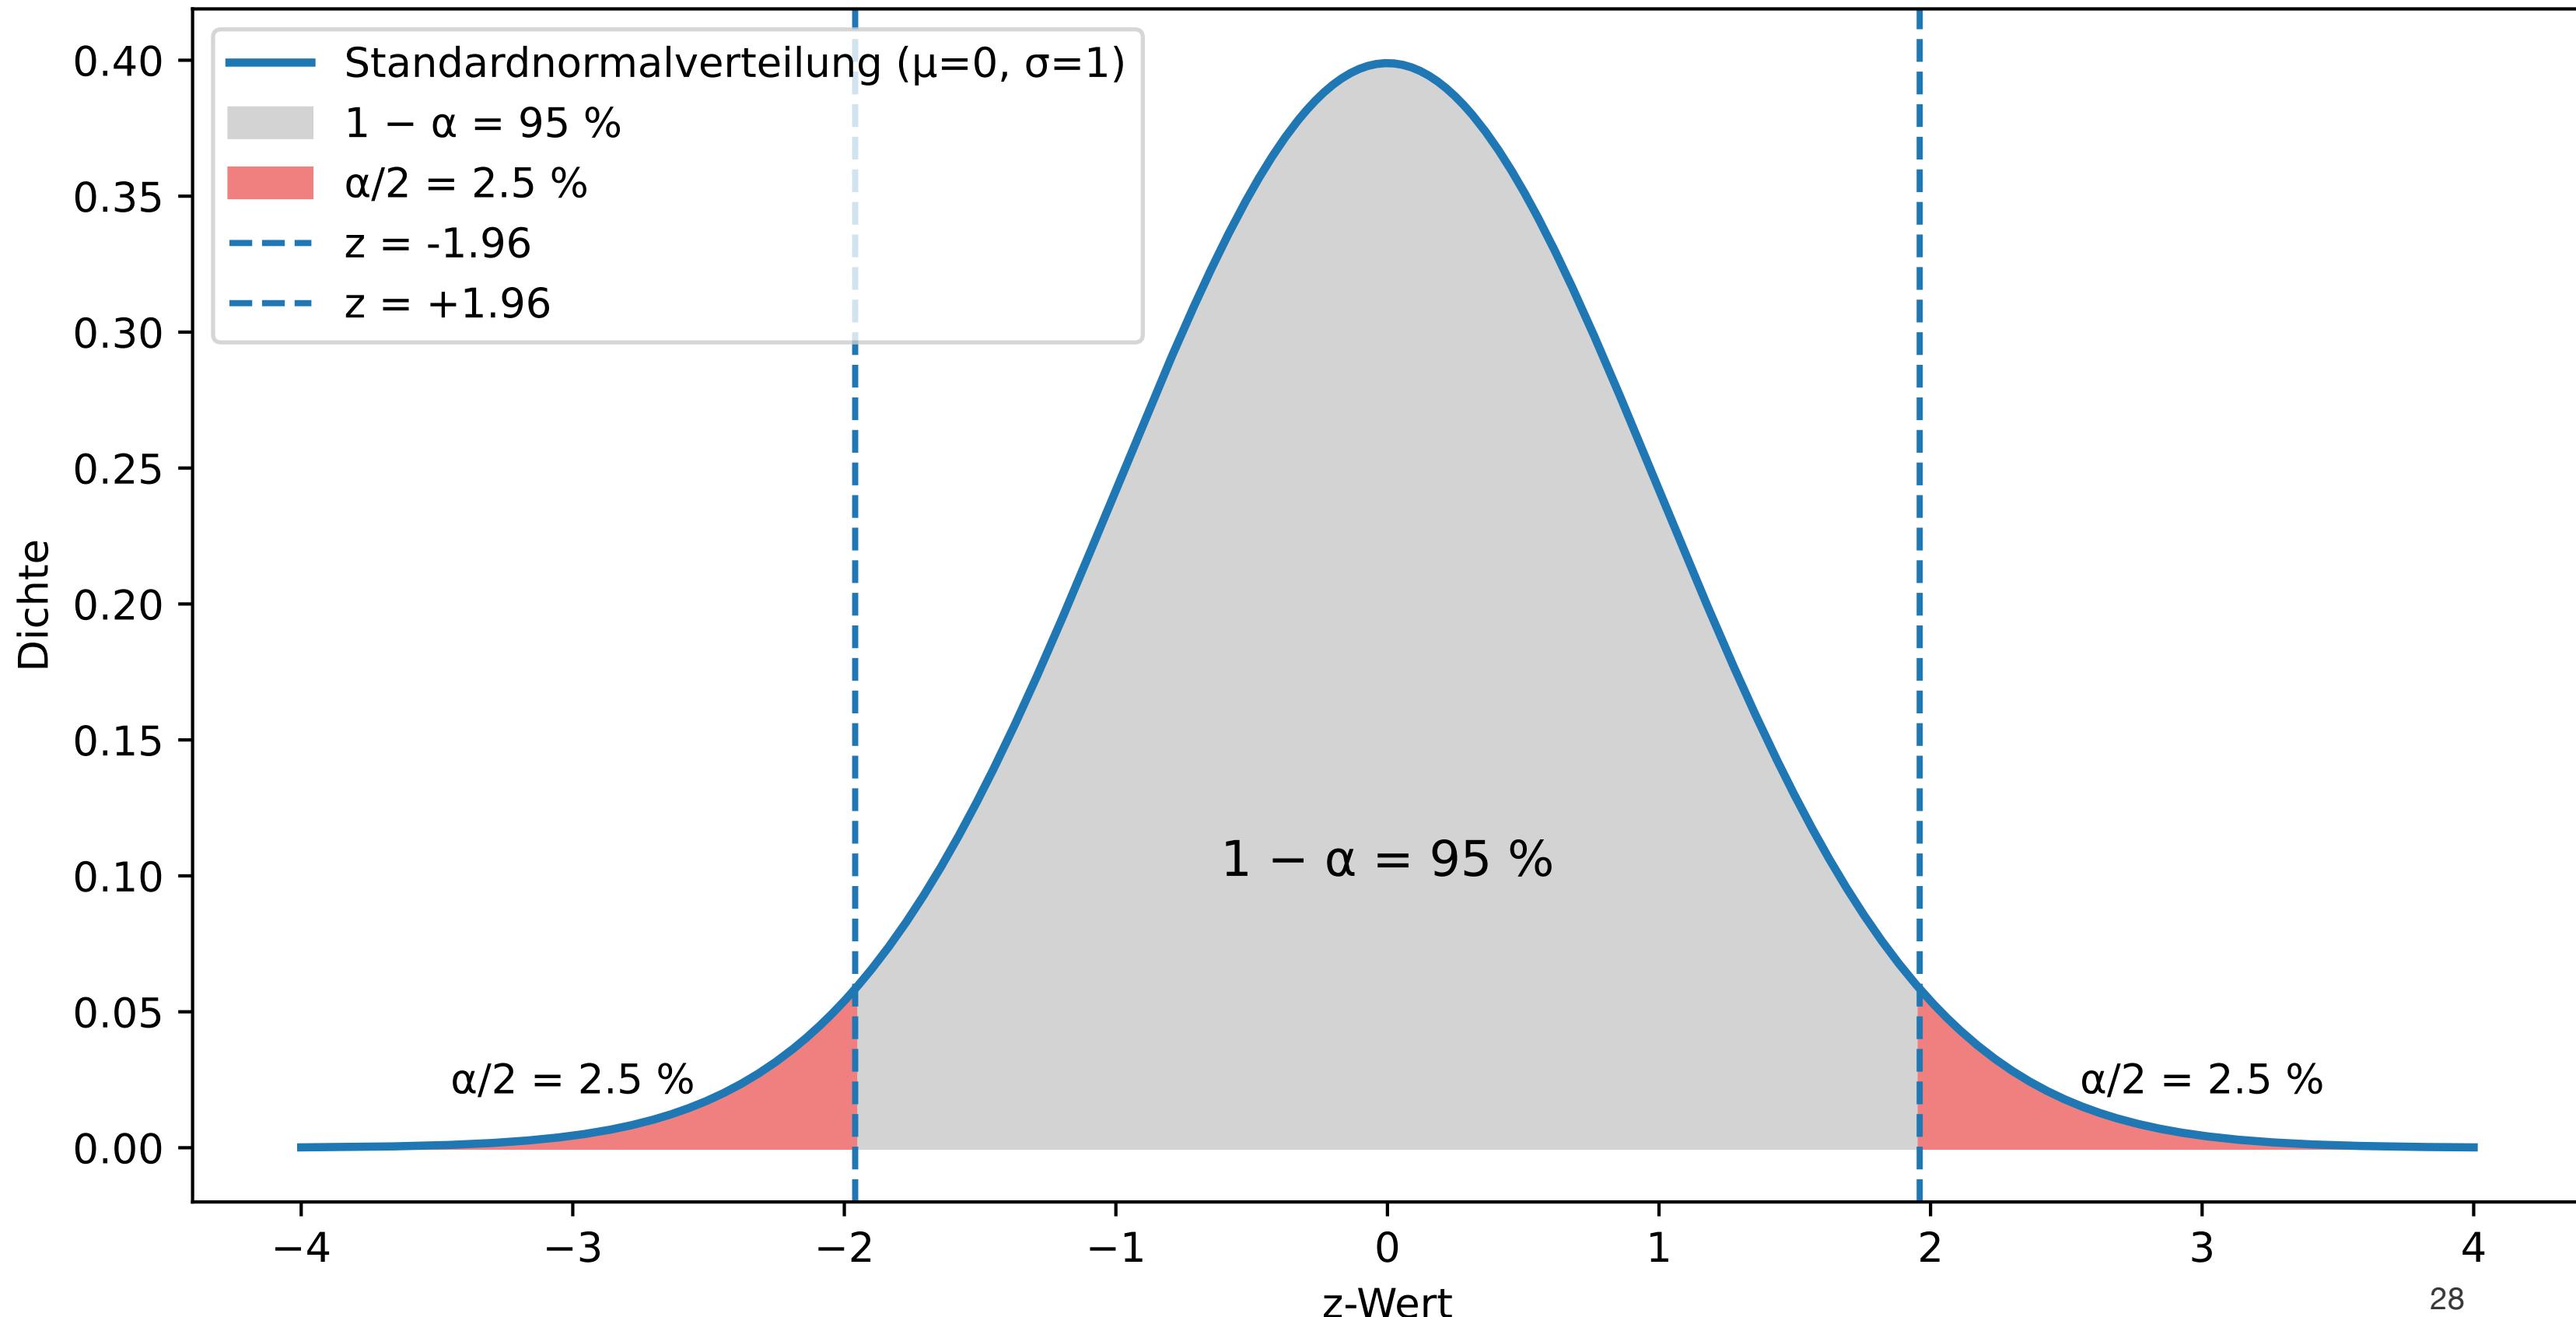
- $\alpha$  ist die Irrtumswahrscheinlichkeit (z. B. 0.05 bei 95 %)
- $1 - 0.05/2 = 0.975 \Rightarrow 97.5\% \rightarrow \text{ergibt } z \approx 1.96$

Beispiel:

Bei 95 % Konfidenz:  $\bar{x} \pm 1.96 \times SE(\bar{x})$

→ Das Intervall enthält mit grosser Wahrscheinlichkeit den wahren  $\mu$ .

# Bedeutung von $(1 - \alpha/2)$ : beide Seiten der Verteilung



# Die z-Verteilung

- Die **z-Verteilung** ist eine **Standardnormalverteilung** mit Mittelwert  $\mu = 0$  und Standardabweichung  $\sigma = 1$ .
- Sie beschreibt, **wie stark standardisierte Werte** (z-Werte) vom Mittelwert abweichen:

$$z = \frac{x - \mu}{\sigma}$$

→ z zeigt, **wie viele Standardabweichungen** ein Wert vom Mittelwert entfernt ist.

- Die z-Verteilung ist symmetrisch und glockenförmig.
  - Etwa **68 %** aller Werte liegen zwischen  $z = -1$  und  $+1$
  - Etwa **95 %** zwischen  $z = -1.96$  und  $+1.96$
- Der Buchstabe **z** steht für **Zufallsvariable der standardisierten Normalverteilung**.  
→ Man kann sagen: «z ist die Sprache der Standardabweichungen».

# Die t-Verteilung

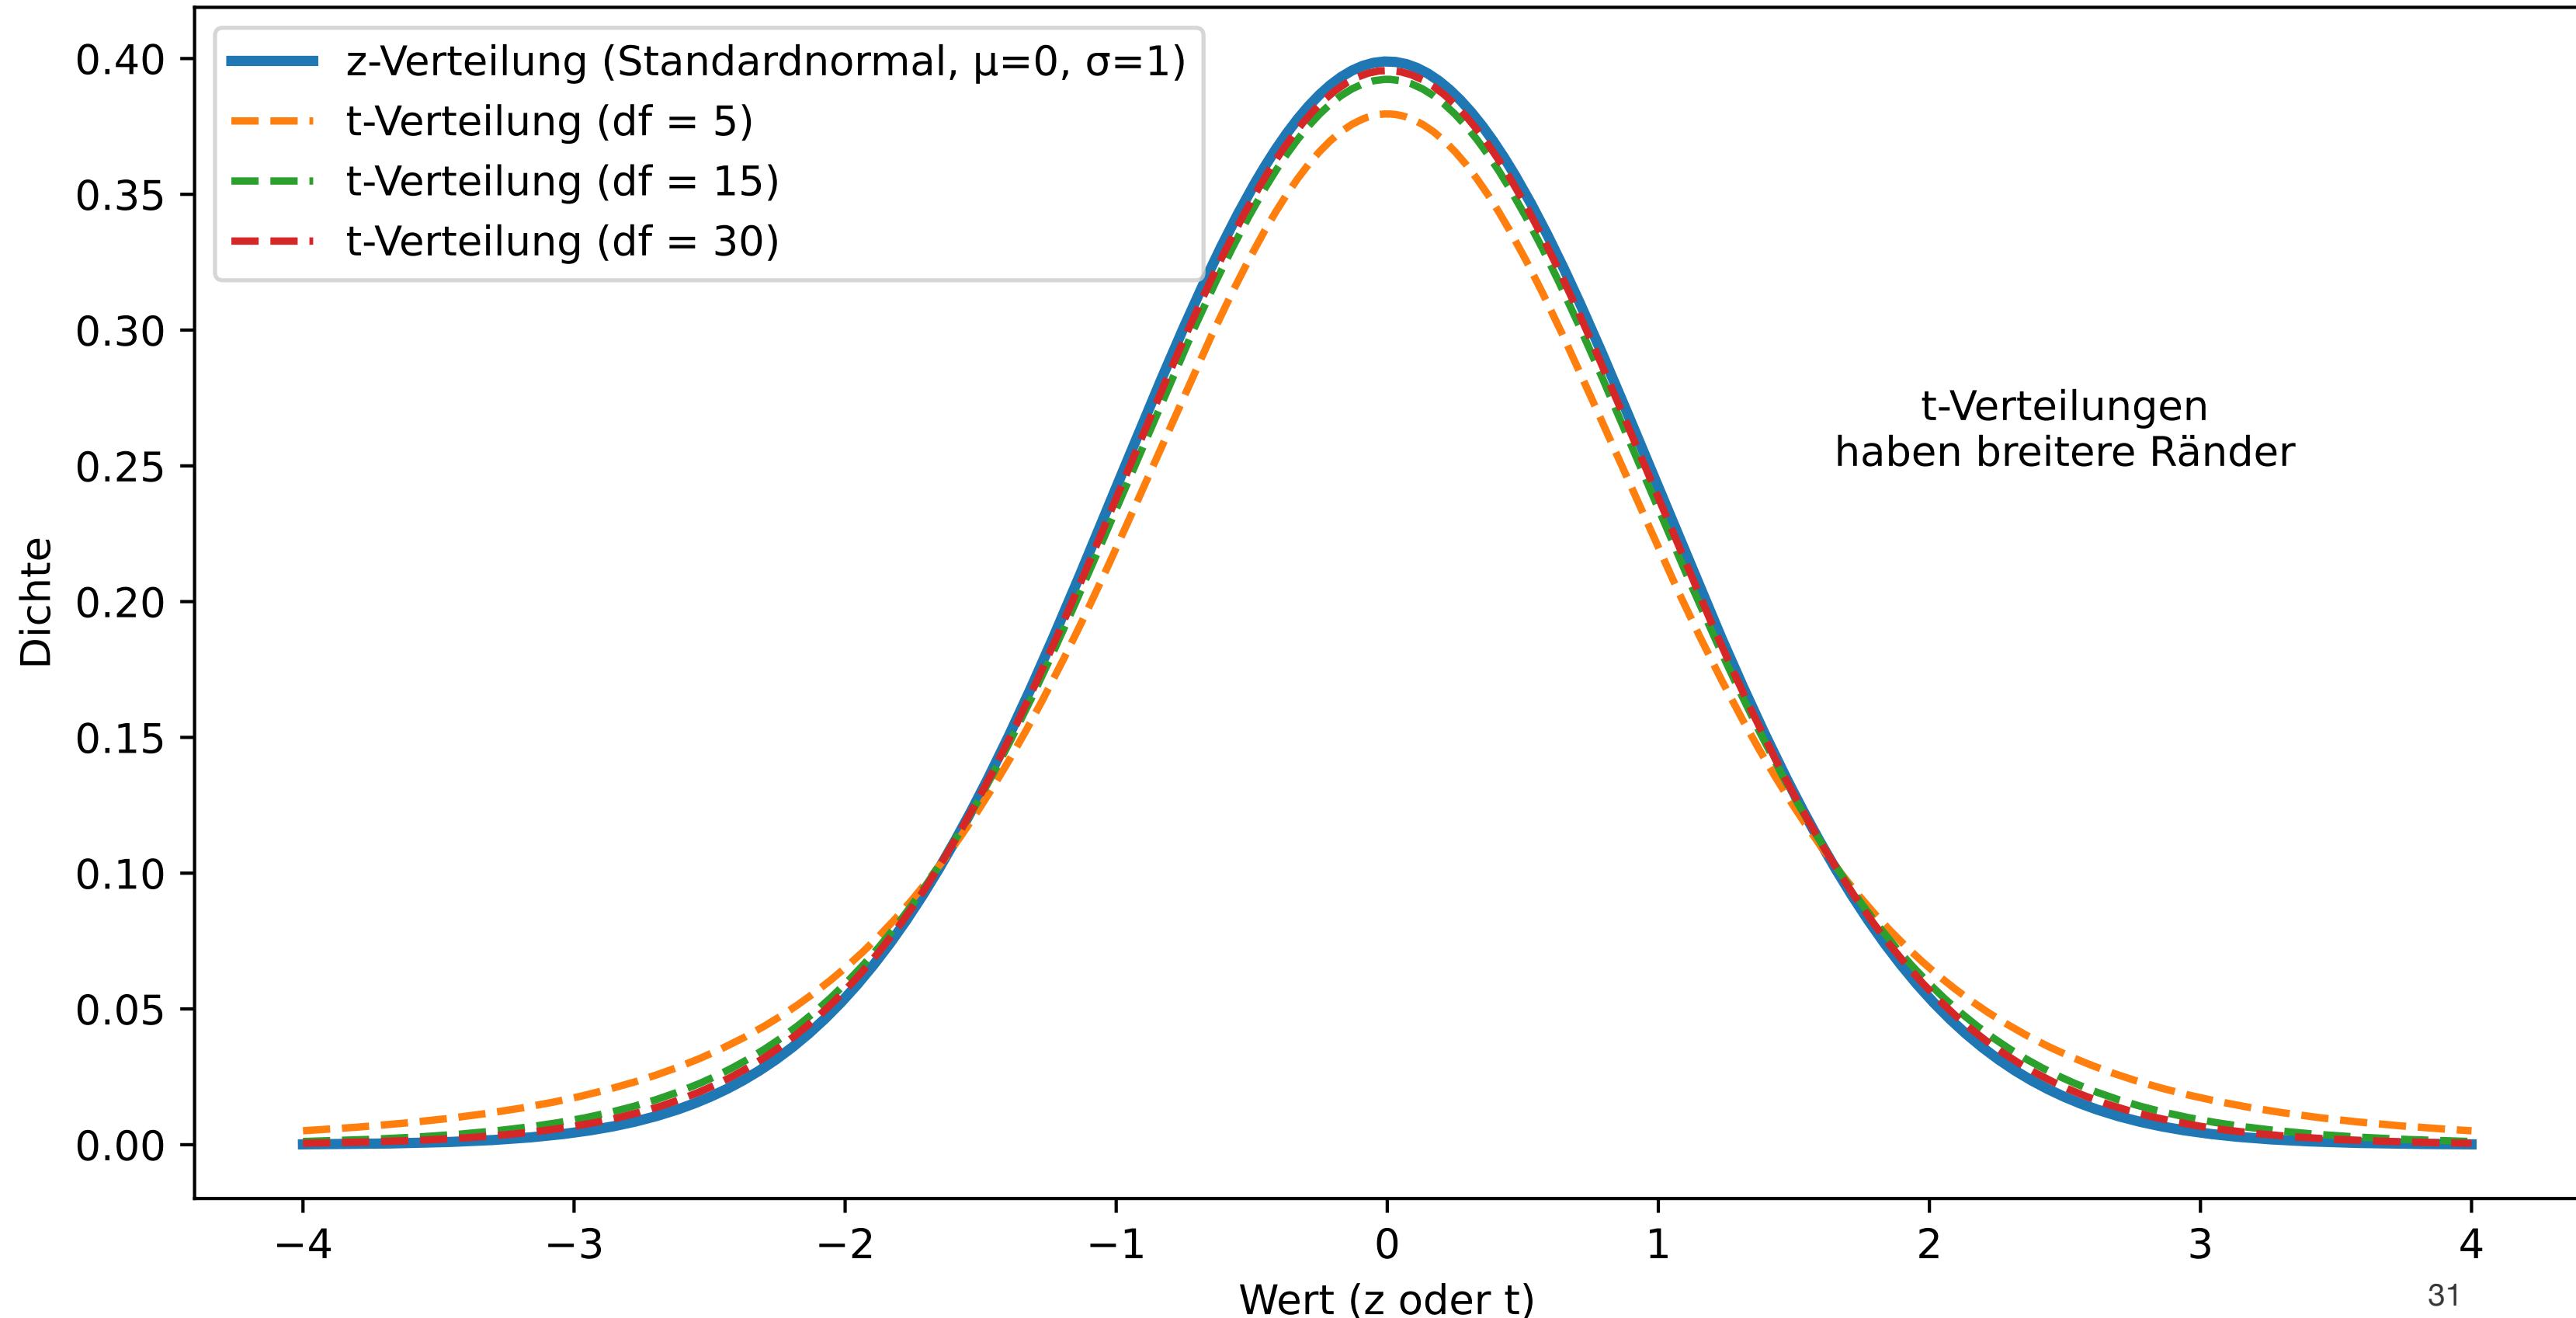
- Die **t-Verteilung** sieht ähnlich aus wie die z-Verteilung, aber sie hat **breitere Flanken** (dickere «Tails»).  
→ Sie berücksichtigt, dass wir  $\sigma$  nicht kennen, sondern nur aus der Stichprobe schätzen.

$$t = \frac{\bar{x} - \mu}{s/\sqrt{n}}$$

→ Statt  $\sigma$  (Populationsstreuung) verwenden wir  $s$  (Stichprobenstreuung).

- Der Buchstabe **t** steht für die **t-Statistik**, eingeführt von **William Sealy Gosset**, der unter dem Pseudonym „**Student**“ veröffentlichte → daher auch „**Student's t-Verteilung**“.
- Die Form der Verteilung hängt von den **Freiheitsgraden (df = n – 1)** ab:
  - Bei kleinen  $n$  → breiter, unsicherer.
  - Bei grossem  $n$  → nähert sich der z-Verteilung an.

# Vergleich: z-Verteilung vs. t-Verteilung (Student)



# Notation: Quick-Ref

Konsistente Symbole senken kognitive Last.

- Population:  $\mu$  (Mittelwert),  $\sigma^2$  (Varianz),  $p$  (Anteil).
- Stichprobe:  $\bar{x}$ ,  $s^2$  (ddof = 1),  $\hat{p}$ .
- SE:  $\text{SE}(\bar{X}) = \sigma/\sqrt{n}$ ,  $\text{SE}(\hat{p}) = \sqrt{\hat{p}(1 - \hat{p})/n}$ .
- Quantile:  $z_{1-\alpha/2} \approx 1.96$  (95 %),  $t_{\text{df}, 1-\alpha/2}$ .

Mini-Check: Welche Größen ändern sich, wenn  $n$  wächst:  $\mu$ ,  $\bar{x}$ ,  $s$ , SE?

# Punktschätzung

# Warum schätzen wir überhaupt?

Schätzen liefert handlungsrelevante Zahlen unter Unsicherheit.

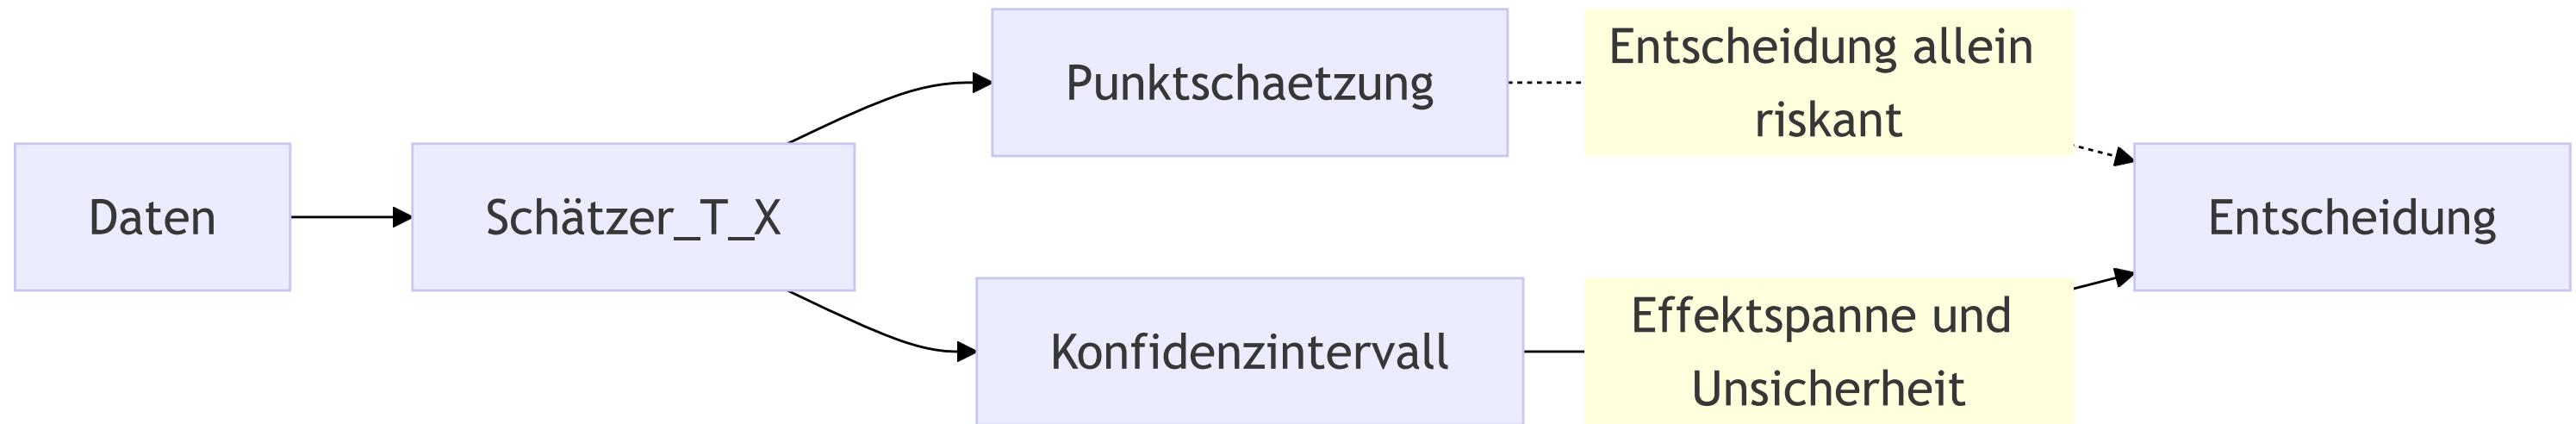
- **Beispiele:** Impf-Effekt, Conversion-Rate, Produktionsausbeute.
- Punktschätzung = Kompass; CI = Sicherheitsgurt.
- **Lernziel:** Punkt- und Intervallschätzer korrekt nutzen.

**Mini-Check:** Nenne ein Entscheidungsproblem, das ohne CI riskant wäre.

# Beispiele

- **Impf-Effekt:** → Wie stark schützt eine Impfung wirklich?  
Beispiel: Von 100 geimpften Personen werden 5 krank, von 100 ungeimpften 20.  
**Impf-Effekt = Unterschied = 15 % weniger Erkrankte.**
- **Conversion-Rate:** → Wie viele Besucher einer Webseite tun das, was man will, z. B. etwas kaufen oder sich anmelden?  
Beispiel: 1000 Besucher, 50 Käufe → **Conversion-Rate =  $50 / 1000 = 5 \%$ .**
- **Produktionsausbeute:** → Wie viele hergestellte Produkte sind wirklich in Ordnung?  
Beispiel: 100 produzierte Teile, 92 fehlerfrei → **Ausbeute = 92 %.**
- In allen drei Fällen schätzen wir **einen Anteil oder eine Wahrscheinlichkeit** → also wie oft etwas «erfolgreich» ist.

# Weg von Daten zur Entscheidungsfindung



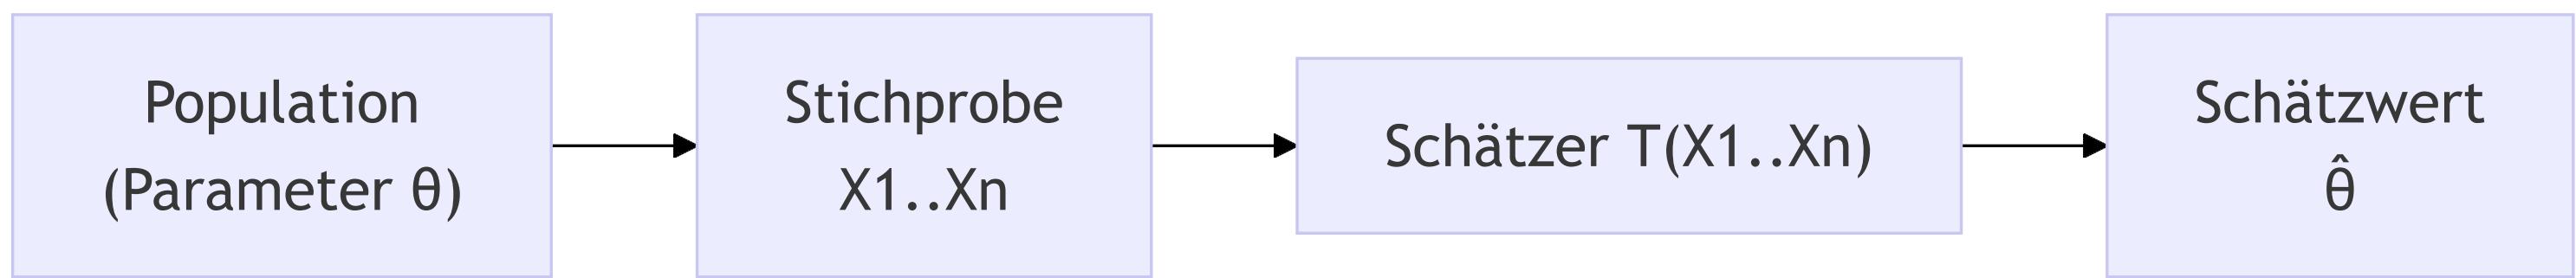
# Schätzer: Definition & Notation

Ein Schätzer ist eine Funktion der Daten für einen Parameter.

- $T(X_1, \dots, X_n) \rightarrow \theta$ , z. B.  $\bar{X} \rightarrow \mu$ ;  $\hat{p} \rightarrow p$ .
- $T$  ist Zufallsvariable mit Erwartungswert und Varianz.
- $\text{MSE}(T) = \text{Bias}(T)^2 + \text{Var}(T)$ .

Mini-Check: Was ist hier zufällig:  $\bar{X}$  oder  $\mu$ ?

# Population zur Schätzung



# Bias & Varianz – zwei Arten von Fehlern

- Wenn wir schätzen, wollen wir den **wahren Wert treffen**, wie beim Dartspiel die Mitte.
- Dabei passieren zwei Arten von Fehlern:

## Bias (systematischer Fehler)

- Bedeutet: **im Durchschnitt daneben zielen**.
- Beispiel: Eine Waage zeigt **immer 2 kg zu viel** → Schätzer ist systematisch zu hoch.
- **Bias** misst, wie weit der **Durchschnitt der Schätzungen** vom **wahren Wert** entfernt ist.
- Ein **unverzerrter Schätzer** hat Bias = 0.



## Varianz (Zufallsschwankung)

- Bedeutet: Die Schätzungen **springen hin und her**.
- Beispiel: Eine Messung schwankt stark – mal 68, mal 74, mal 70.
- **Varianz** zeigt, wie stark die **Ergebnisse zwischen Stichproben schwanken**.

# Modell-Bias: Vereinfachung mit Absicht

- Modell-Bias entsteht, wenn wir die Welt **bewusst vereinfachen**, um stabile und verständliche Schätzungen zu bekommen.

 Was heisst Modell bei Schätzern?

Ein **Modell** ist eine **Annahme über die Struktur der Daten**:

- Wie sehen die Werte aus? (z. B. normalverteilt oder schieß?)
- Wie hängen sie zusammen? (z. B. linear oder gekrümmmt?)
- Welche Größen sind fix, welche zufällig?

 Beispiele für Modell-Annahmen:

- **Normalverteilung:** Viele Schätzer (z. B. t- und z-Intervalle) nehmen an, dass Daten **symmetrisch verteilt** sind.
- **Linearität:** Regressionsschätzer gehen davon aus, dass Zusammenhänge **gerade Linien** sind.
- **Unabhängigkeit:** Jeder Messwert ist **eigenständig** und beeinflusst keinen anderen.
- **Homogene Varianz:** Die Streuung der Daten ist überall etwa gleich.

# Varianz: Warum Schätzungen zufällig sind

Jede **Stichprobe** ist anders → Schätzungen schwanken zufällig. Diese Streuung nennt man **Varianz** des Schätzers.



## Zufallsquellen beim Schätzen

### 1. Zufällige Auswahl:

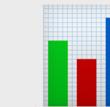
Wer in der Stichprobe landet, ist Zufall → andere Personen → anderer Mittelwert.

### 2. Messrauschen:

Kleine Messfehler verändern die Werte leicht.

### 3. Modellunsicherheit:

Wenn das Modell nicht perfekt passt, schwanken Schätzungen stärker.



## Folge:

Schätzer haben keine feste Zahl, sondern eine **Verteilung von möglichen Werten**.

Der **Standardfehler (SE)** misst diese Streuung:

$$SE = \frac{SD}{\sqrt{n}}$$

→ Mehr Daten = kleinere Varianz = stabilere Schätzungen.

# Gütekriterien: Bias, Varianz & Effizienz

- **Bias** = Schätzer liegt im Durchschnitt **systematisch daneben**. → Beispiel: Waage zeigt immer +2 kg.
- **Varianz** = Schätzer **schwankt** stark zwischen Stichproben. → Beispiel: Messwerte springen zwischen 68 und 75.
- **Erwartungstreue:**  $E[T] = \theta$  → Schätzer trifft den wahren Wert **im Mittel**.
- **Effizienz:** Unter allen erwartungstreuen Schätzern hat dieser die **kleinste Varianz** → **stabilster Schätzer**.
- **Bias–Varianz–Trade-off:**  $MSE = \text{Bias}^2 + \text{Varianz}$  → Ein **kleiner Bias** kann gut sein, wenn die **Varianz stark sinkt** → stabiler Gesamtfehler.

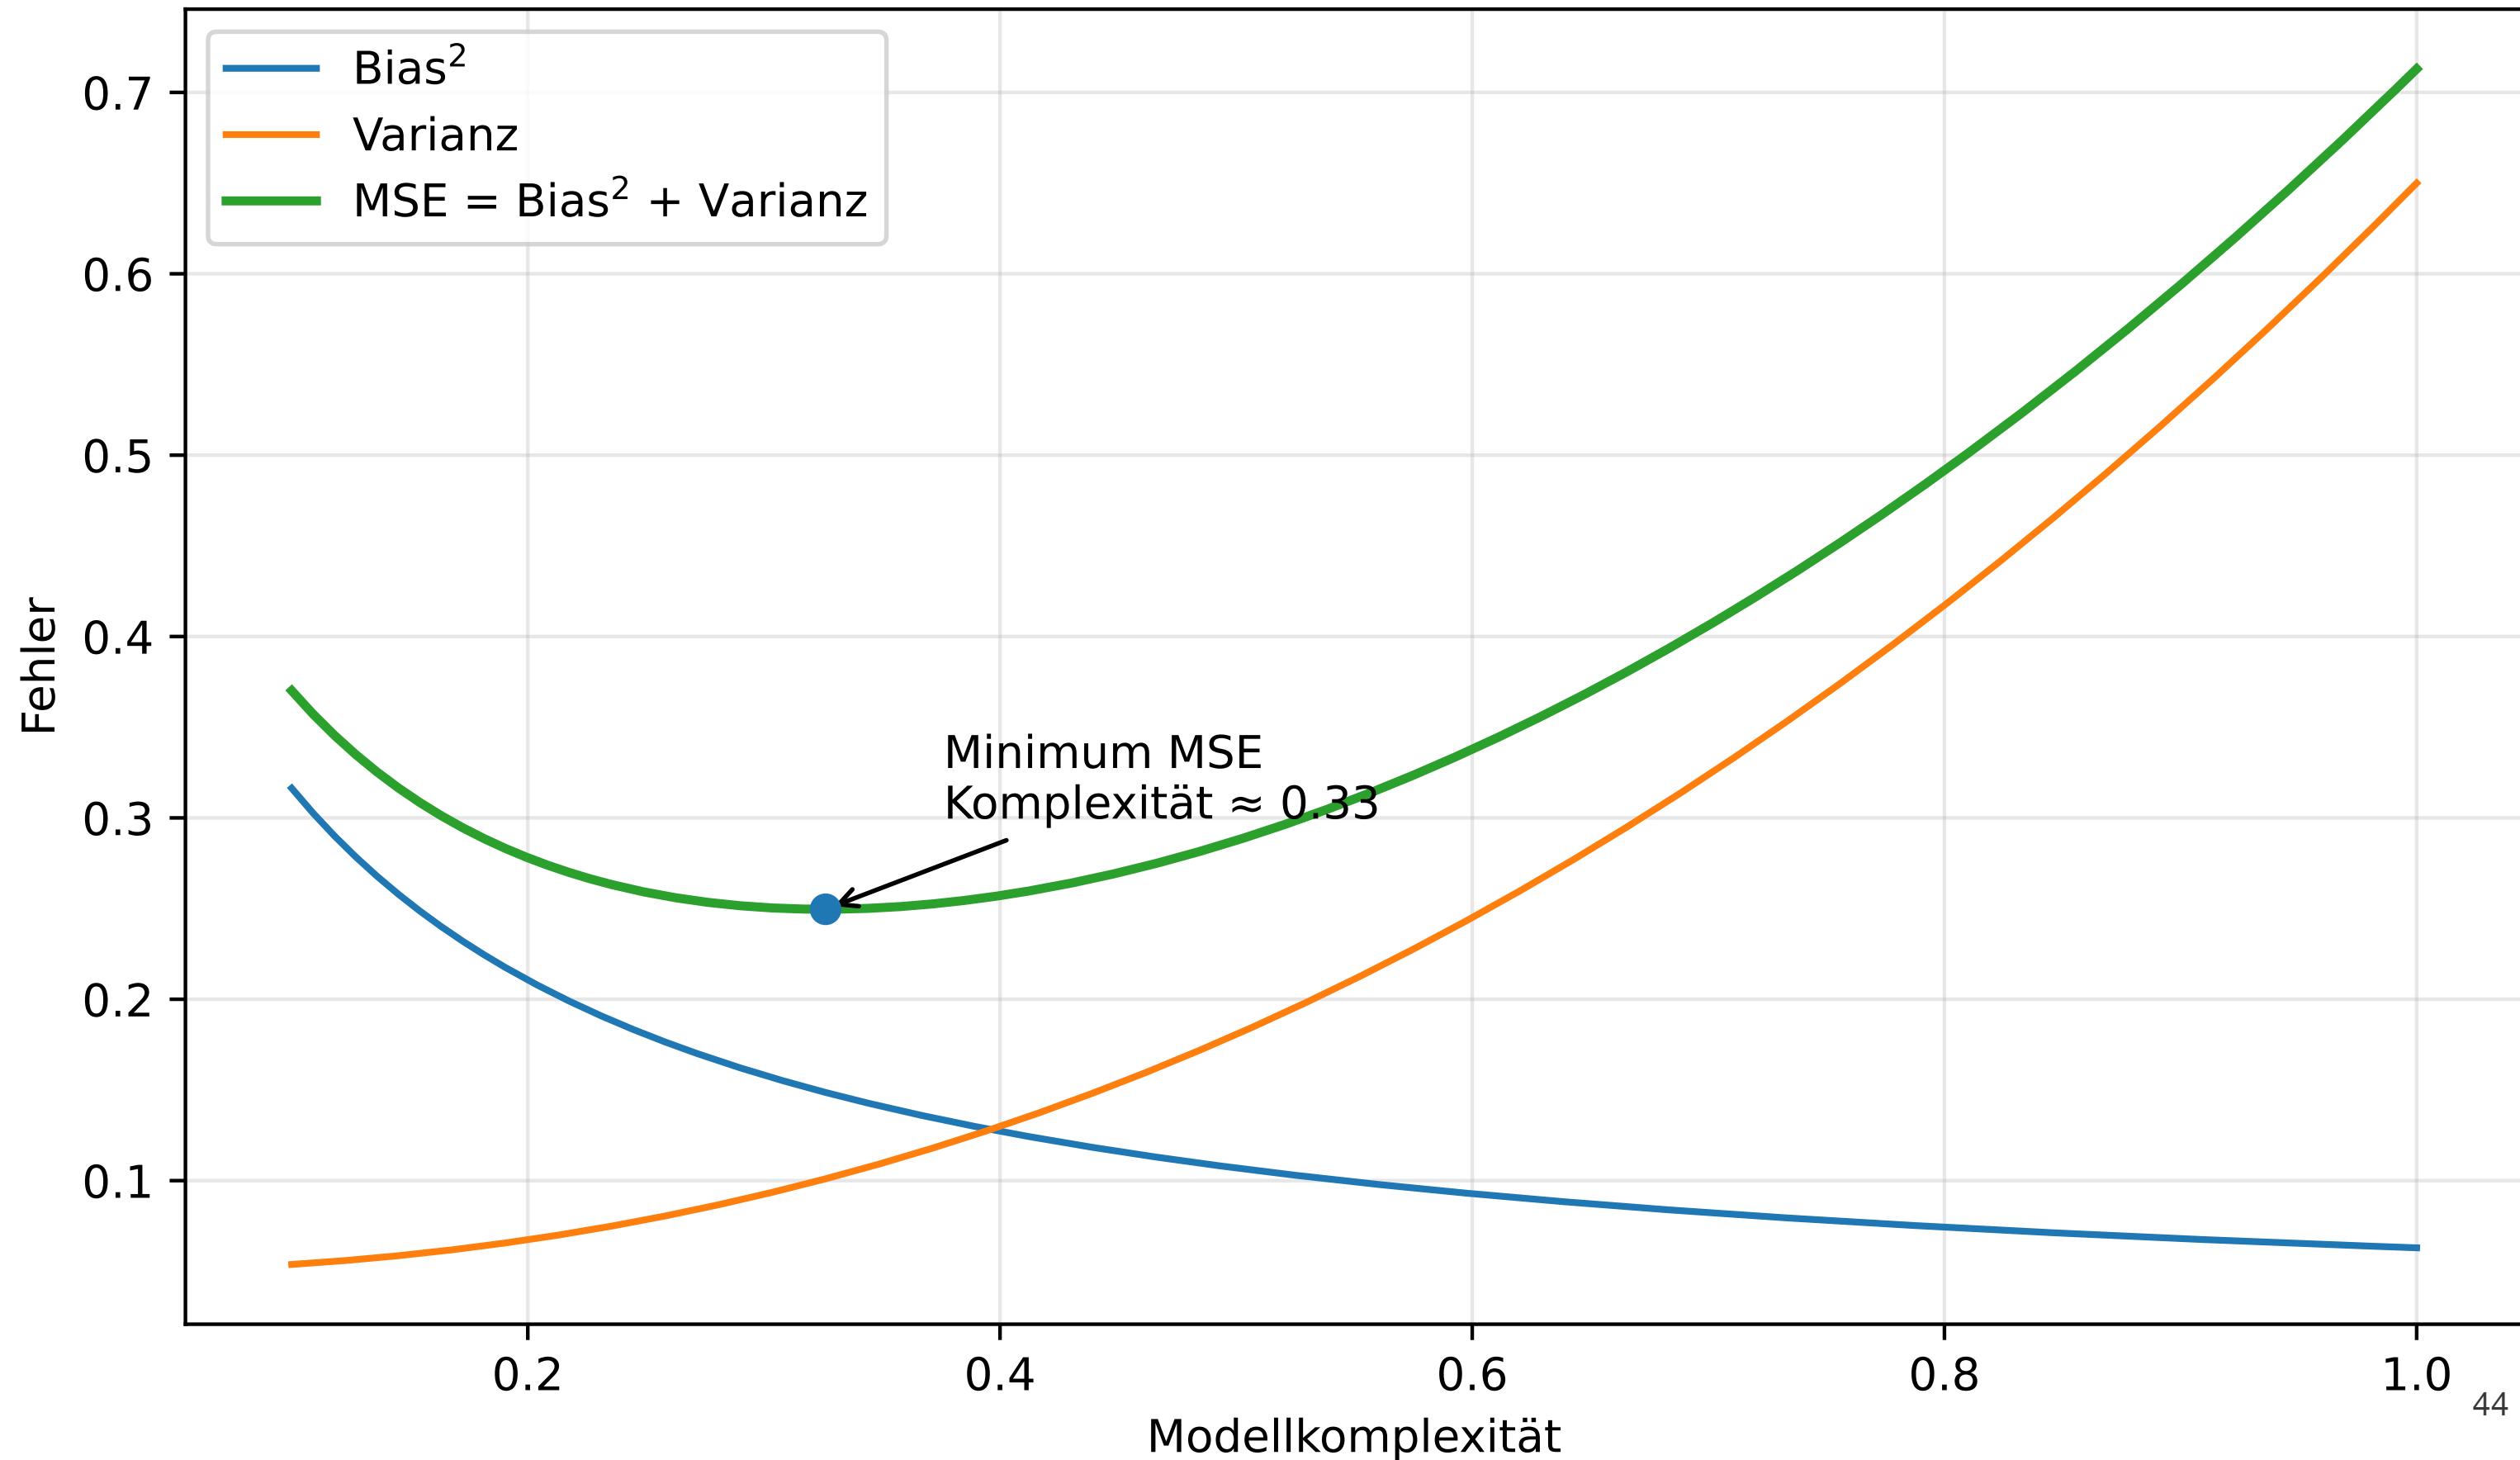
# Gütekriterien (Bias, Varianz, Effizienz)

Gute Schätzer balancieren Bias und Varianz.

- Erwartungstreue:  $\mathbb{E}[T] = \theta$ .
- Effizienz: kleinste Varianz unter erwartungstreuen Schätzern.
- Bias–Varianz–Trade-off: minimale MSE ist Ziel.

Mini-Check: Nenne ein Setting, in dem kleiner Bias akzeptabel ist.

# Bias-Varianz-Trade-off: MSE-Kurve vs. Komplexität



# Mean Squared Error (MSE)

Der MSE misst, wie gut ein Schätzer im Durchschnitt trifft.

$$\text{MSE} = \text{Bias}^2 + \text{Varianz}$$

- Bias<sup>2</sup> → systematische Abweichung (immer leicht daneben).
- Varianz → Zufallsschwankung (mal zu tief, mal zu hoch).
- Beide zusammen ergeben den Gesamtfehler.

 Ziel: Den MSE minimieren  
→ bestmöglicher Kompromiss zwischen

«nicht schief» (kleiner Bias) und «nicht zitterig» (kleine Varianz).

# Standardfehler (SE) vs. Standardabweichung (SD)

SE misst die Streuung des Schätzers, SD die Streuung der Daten.

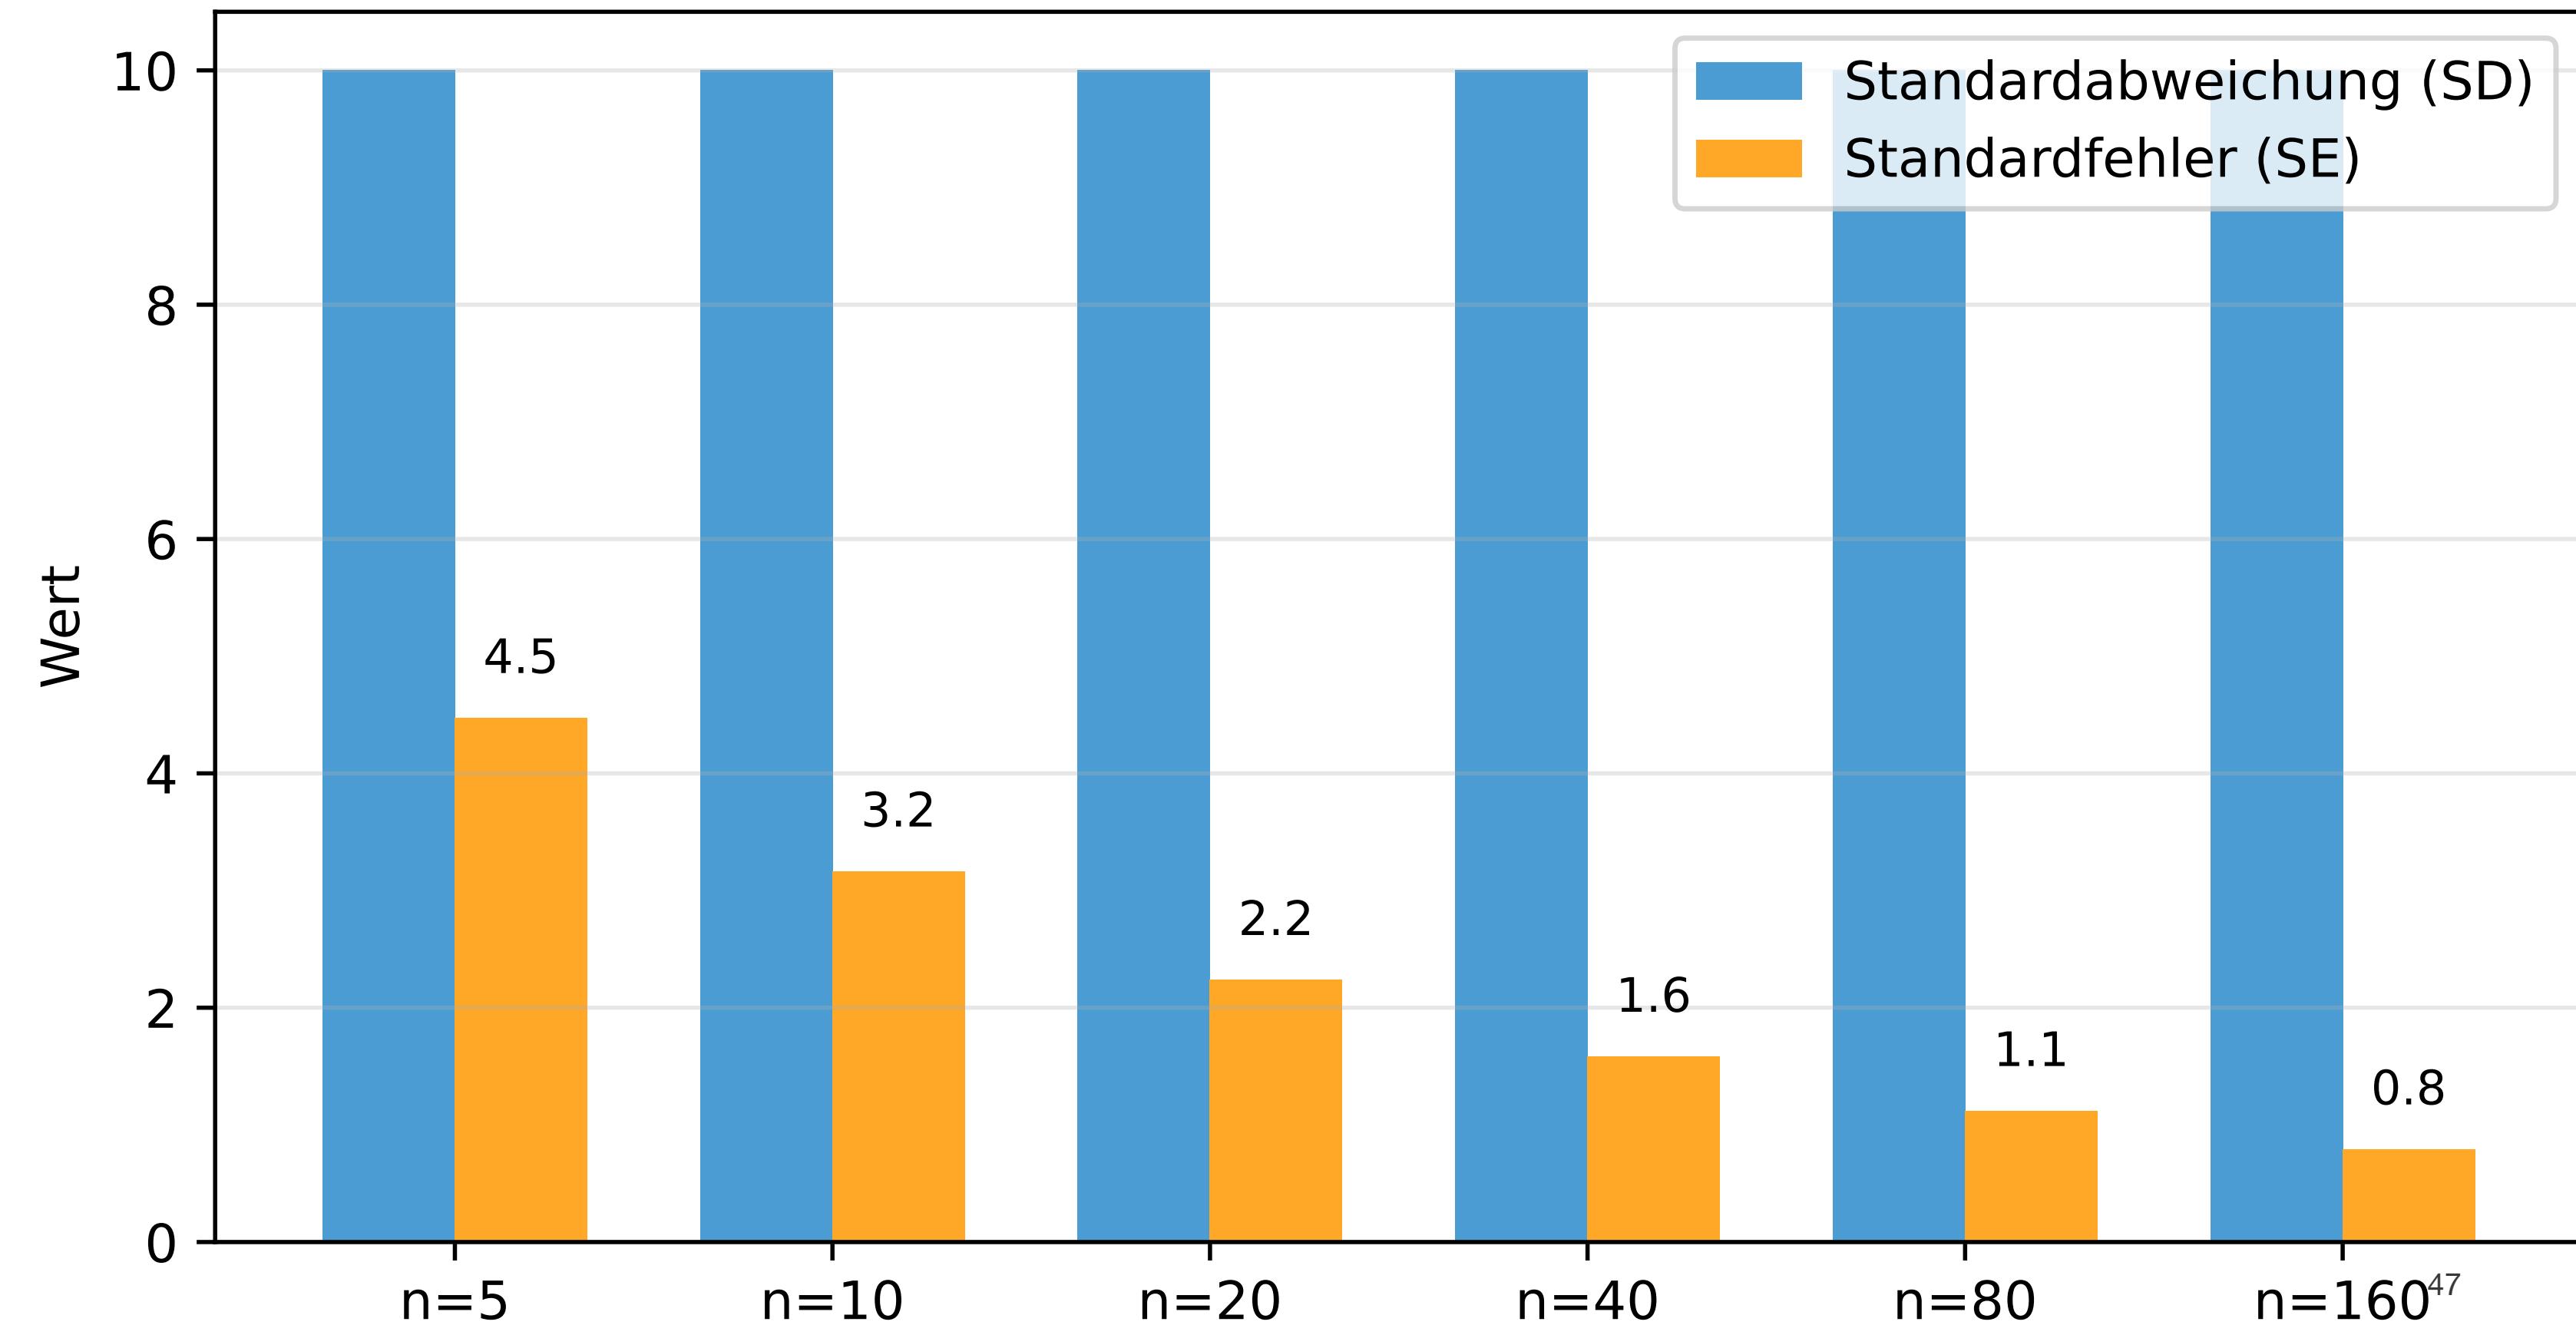
$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}} \quad SD(X) = \sigma$$

- Verdoppeln von  $n$  senkt den Standardfehler um den Faktor  $\sqrt{2}$ , die Standardabweichung der Daten bleibt gleich.
- In der Praxis bestimmt der Standardfehler die Breite des Konfidenzintervalls.

Mini-Check:

Warum sinkt SE mit  $n$  -- SD aber nicht?

# Standardfehler (SE) schrumpft mit n, SD bleibt konstant



# Beispiel Punktschätzung: Münzwurf

- Wir wollen den **Anteil „Kopf“** beim Münzwurf schätzen.
- 10 Würfe, 7 Köpfe → beobachteter Anteil  $\hat{p} = 0.7$   
→ das ist unsere **Punktschätzung** für den wahren Anteil  $p$ .
- Wie stark kann diese Schätzung schwanken? → das misst der **Standardfehler**:

$$SE(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \quad SE(\hat{p}) = \sqrt{\frac{0.7 \cdot 0.3}{10}} \approx 0.145$$

- Interpretation: Wenn wir das Experiment oft wiederholen, schwankt  $\hat{p}$  etwa um  $\pm 0.15$ .

**Mini-Check:** Warum  $\hat{p}$  im SE statt  $p$ ?

# Beispiel: Münzwurf in Python

```
import numpy as np
rng = np.random.default_rng(123)

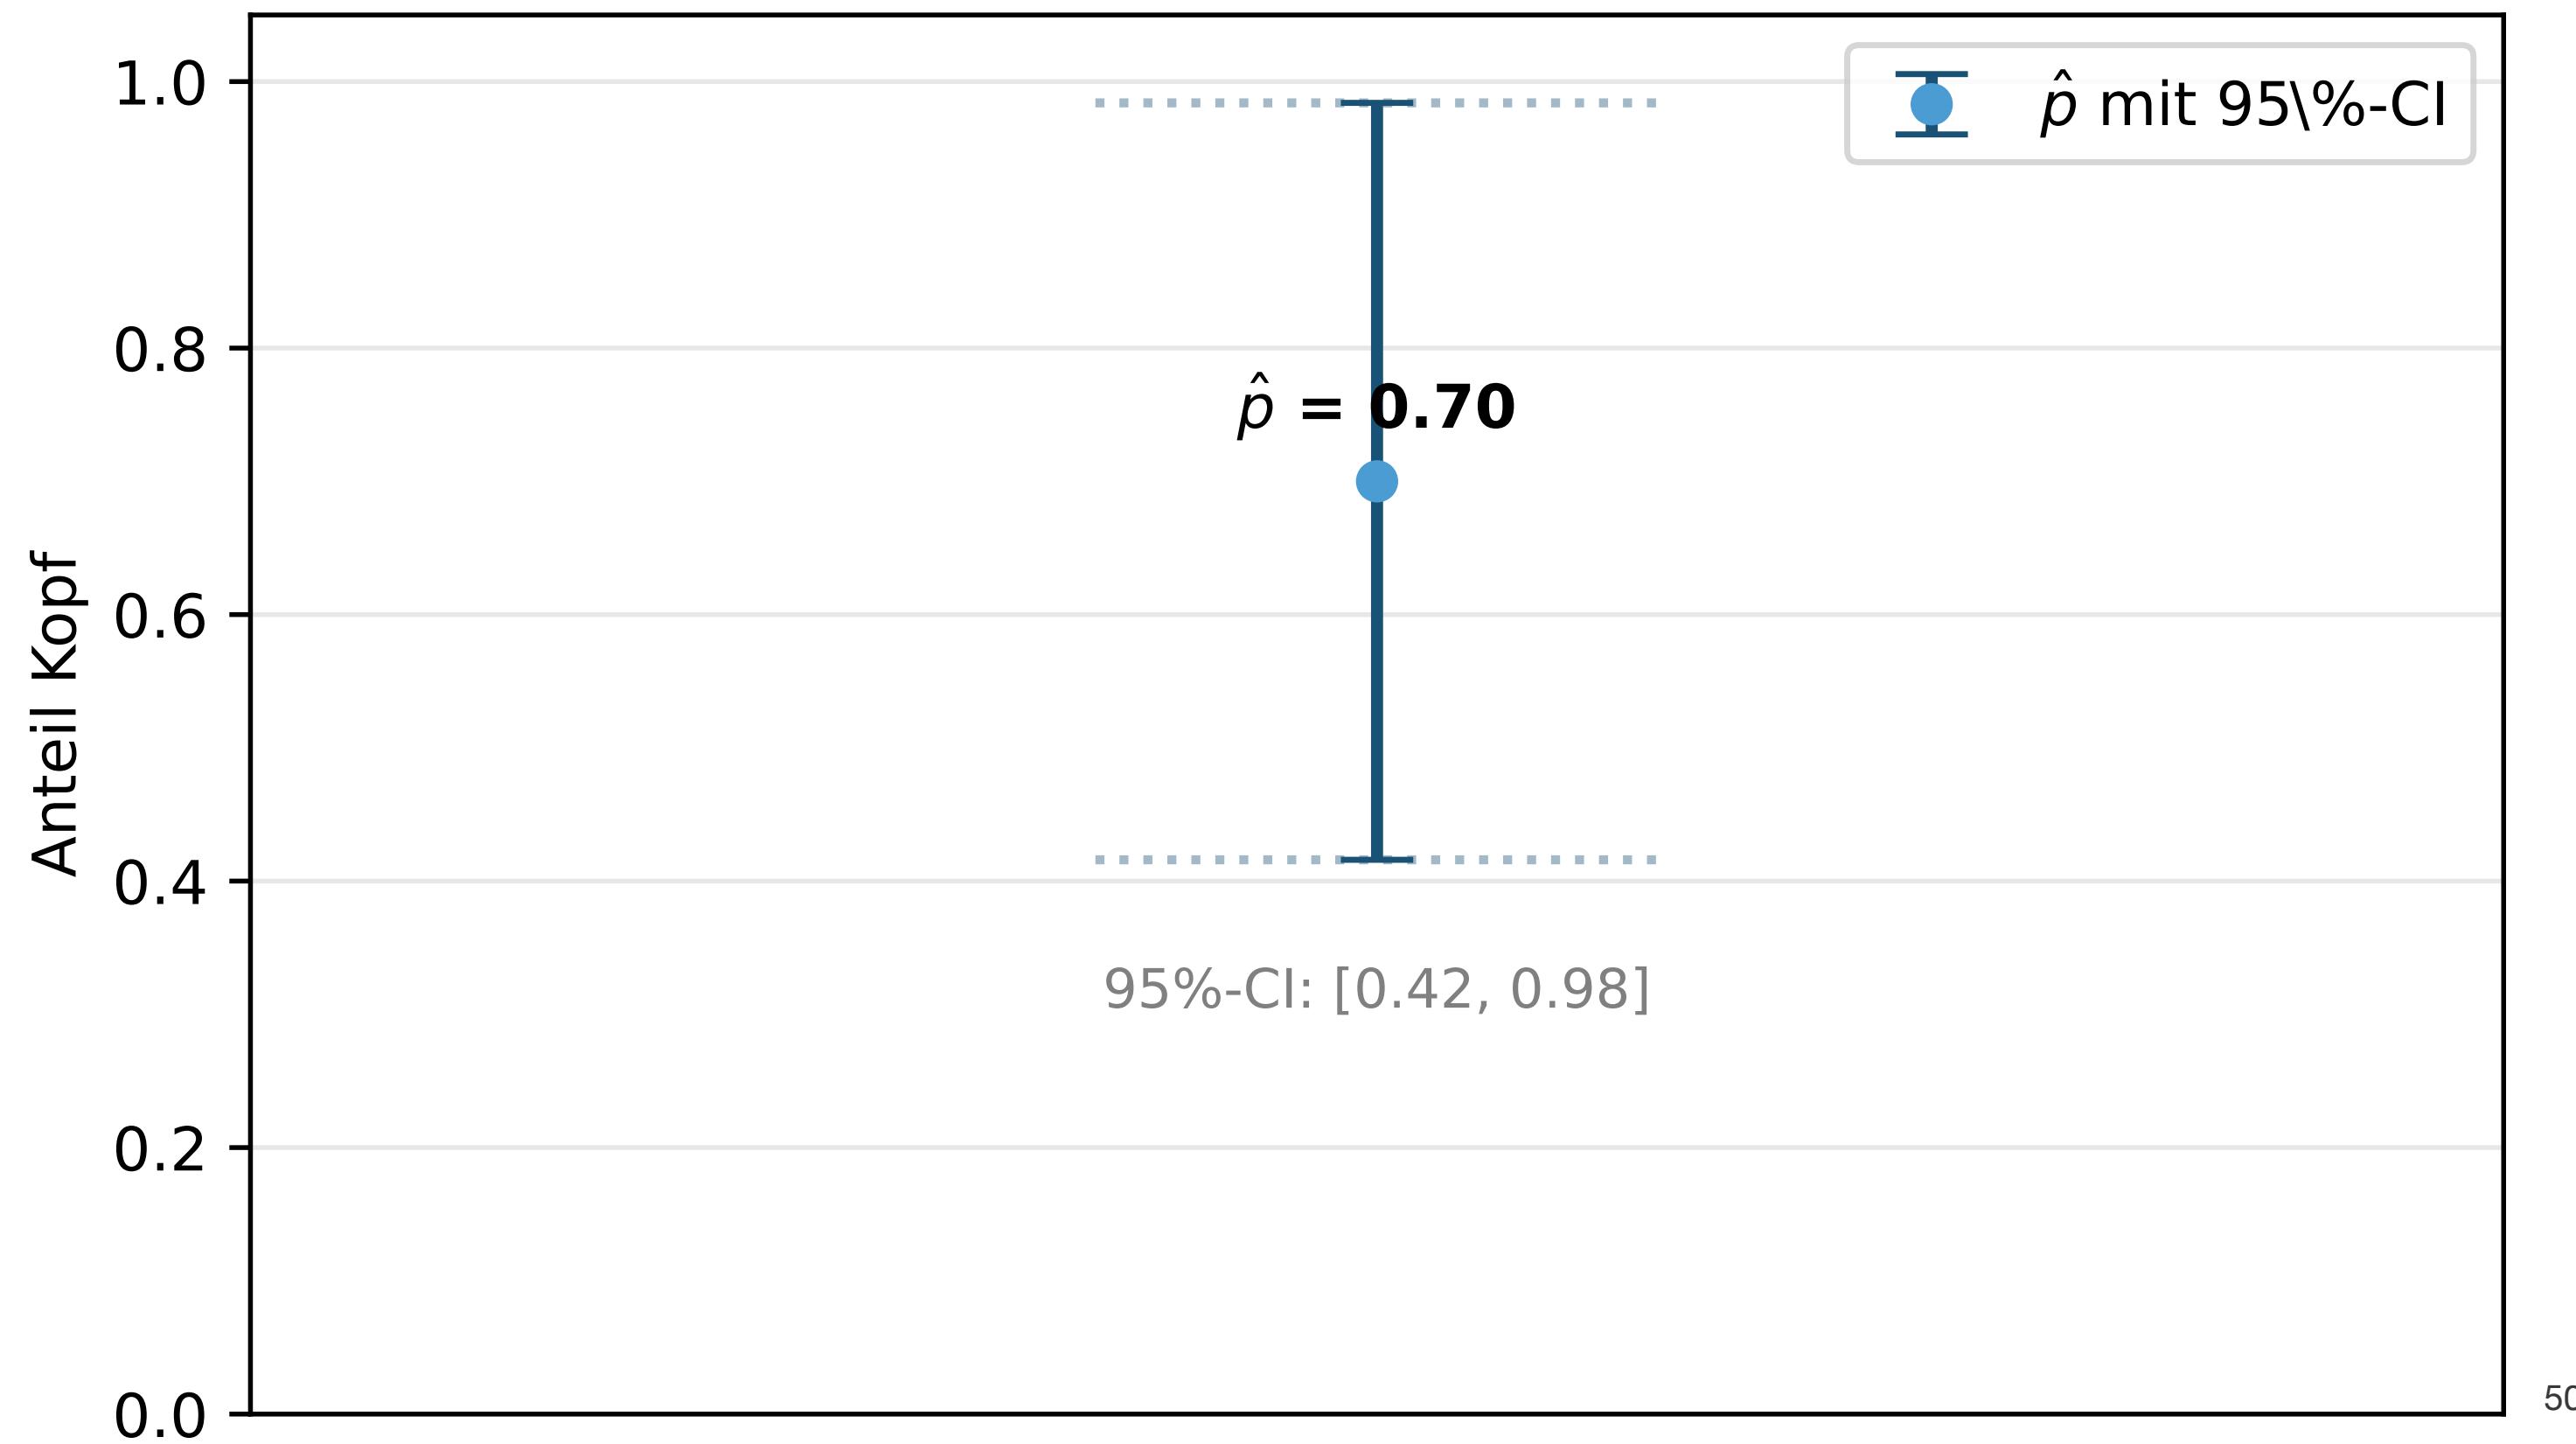
# 20 Münzwürfe, Wahrscheinlichkeit für "Kopf" = 0.6
x = rng.binomial(1, 0.6, 20)

# Punktschätzung und Standardfehler
p_hat = x.mean()
se = np.sqrt(p_hat * (1 - p_hat) / len(x))

p_hat, se
```

- Der Code simuliert **20 Münzwürfe**, berechnet  $\hat{p}$  und  $SE(\hat{p})$ .
- Beispieldaten: **(0.55, 0.111)** → Anteil Kopf = **55 %**, Standardfehler  $\approx$  **0.11**.
- Wenn du den Code mehrfach ausführst, ändern sich die Ergebnisse leicht → **Zufall!**
- Je grösser **n**, desto kleiner wird der **Standardfehler**.

# Punktschätzung beim Münzwurf: $\hat{p}$ und 95%-Konfidenzintervall



# Zusammenfassung & Ausblick

# Gesamt-Take-Away: Punkt, Spanne, Planung

Statistik ist die Kunst, **Unsicherheit nützlich zu machen**: mit Schätzung, Intervall und guter Planung.

- Punktschätzung ist der **Kompass**: eine beste Zahl aus begrenzten Daten.
- Konfidenzintervall ist der **Sicherheitsgurt**: zeigt die **Spanne und Unsicherheit**.
- Standardfehler ist der **Taktgeber**: bestimmt, wie **breit** die Spanne wird.
- Wilson statt Wald bei **Anteilen**: ehrlicher und immer zwischen 0 und 1.
- Bootstrap macht Unsicherheit sichtbar, wenn **Formeln wackeln**.
- Stichprobengrösse via **Margin of Error**: Präzision ist **planbar**, aber **teuer im Quadrat**.
- Bias–Varianz–Trade-off: lieber **kleiner Bias** und **stabile Schätzung** als perfekter, aber **wackeliger Wert**.

# Quiz - Aktive Wiederholung

Kahoot Quiz VL5: Wahrscheinlichkeit & Verteilungen

# Wrap-up & Nächstes Mal

Primer, Population, Stichprobe, Punktschätzung.

Online:

- Konfidenzintervalle
- Bootstrap

Nächste Sitzung:

- Hypothesentests ( $H_0/H_1$ ), Fehlerarten, t,  $(\chi^2)$ .